

EmpatIA 2024 · Apéndice metodológico

El informe completo, con todo el detalle detrás de cada cifra

Tabla de contenidos

1. Cómo leer este apéndice	3
2. El estudio	4
2.1. Alcance y fuentes	4
2.2. El diseño de exposición: quién ve qué	4
2.2.1. Filtro 1: una industria por persona	4
2.2.2. Filtro 2: hasta quince marcas en la batería de atributos	4
2.2.3. Controles de diseño	5
2.2.4. Qué queda pendiente en este bloque	5
2.3. Ponderación: dos correcciones que se multiplican	5
2.3.1. El ponderador muestral	5
2.3.2. Ponderación por la inversa de la probabilidad de exposición	6
2.4. Limpieza y población de análisis	10
2.5. Perfil de la muestra	10
2.6. Denominadores: qué cambió respecto de ediciones anteriores	11
3. Qué esperan las personas de una marca	14
3.1. Importancia declarada de los atributos	14
3.2. La misma pregunta dentro de cada público	15
3.3. Expectativa de equilibrio y disposición a pagar	16
3.4. Actitud frente a la inteligencia artificial	17
3.5. El bloque de inteligencia artificial, cifra por cifra	18
3.5.1. Los denominadores, que no son todos el mismo	18
3.5.2. Los índices derivados	18
3.5.3. El margen de cada cifra	18
3.5.4. Los cortes	19
4. El ranking	19
4.1. Índice, atributos y dimensiones	19
4.2. Construcción de los cuatro rankings publicados	19
4.3. Incertidumbre de los resultados descriptivos	20
4.4. Las tres referencias: categoría, industria y estudio	21
4.5. El mapa de cercanía y tecnología	22
5. El recorrido de la marca y sus conversiones	23
5.1. Las tres etapas	23
5.2. Las funciones de conversión	23
6. Qué pesa en la elección	26
6.1. Importancia declarada e importancia derivada	26
6.2. Ganancia de usar el ranking completo	27

6.3. Por industria y por desenlace	28
6.4. Cuánto pesa cada bloque	29
7. Fortalezas y debilidades	30
7.1. La matriz de importancia y perfilamiento	30
7.2. Perfilamiento dentro de la categoría	31
8. ¿Y si el índice usara todos los atributos?	32
8.1. Unidad de análisis	32
8.2. Dimensionalidad	32
8.3. Proporción atribuible a una dimensión general	32
8.4. Discriminación de los ítems	33
8.5. Índices comparados	34
8.6. Criterio de comparación	34
8.7. Estabilidad	34
8.8. Alternativa evaluada y descartada	35
8.9. Consecuencia sobre el ranking	35
8.10. Comportamiento de los ítems entre públicos	35
8.11. Limitaciones de esta sección	36
9. Resultados por público	37
9.1. Construcción	37
10.El mapa de calor por público y su descomposición	38
10.1. La matriz	38
10.2. Precisión de cada celda	38
10.3. Separación entre perfil y público	38
10.4. Estabilidad del espacio entre públicos	39
10.5. Métodos considerados y descartados	39
11.Perfiles de personas que las segmentaciones habituales no ven	40
11.1. Unidad y espacio	40
11.2. Dos métodos, dos preguntas	40
11.3. Estabilidad	40
12.Territorios de marcas	42
12.1. Orientación de los ejes	42
13.Posicionamiento: cómo se construye el mapa	43
14.Del modelo de elección a los escenarios	44
14.1. Regularización y evaluación fuera de muestra	44
14.2. Escenarios de marca y público	44
14.3. Derivación	45
14.4. Alcance de la lectura	45
15.Un modelo de la preferencia en el tiempo	46
15.1. Especificación	46
15.2. Separación entre y dentro	46
15.3. Interpretación de los coeficientes	46
15.4. Robustez	47
15.5. Limitaciones	47
16.Tendencias entre ediciones	48
16.1. Comparación de dos encuestas independientes	48
16.2. Control de comparaciones múltiples	48

16.3. Regla temporal	48
17.¿Alcanza un modelo aditivo?	50
17.1. La pregunta	50
17.2. Cómo se estima	50
17.3. Cómo se compara	50
17.4. Qué resulta, y cómo leerlo	51
17.5. La tesis del estudio, puesta a prueba directamente	51
17.6. Qué aprendió la forma ganadora	52
17.7. Límites de este capítulo	53
18.Reproducibilidad, controles y límites del estudio	54
18.1. Cómo se reproduce una edición	54
18.2. Controles automáticos	54
18.3. Los seis límites que conviene tener presentes	54
18.4. Referencias metodológicas	55

1. Cómo leer este apéndice

Este documento sigue **el mismo orden del informe**, sección por sección. Donde el informe muestra una lámina, aquí aparece qué se calculó, con qué fórmula, bajo qué supuestos, qué resultados adicionales existen y qué no se puede concluir.

Cada capítulo está organizado igual:

1. **Qué muestra el informe.** La afirmación que se hace y con qué cifra.
2. **Cómo se calcula.** Fórmula, denominador, población incluida.
3. **Supuestos.** Lo que tiene que ser cierto para que la cifra signifique lo que dice.
4. **Detalle estadístico.** Estimación, error, criterios de decisión.
5. **Robustez y resultados adicionales.** Lo que se probó y no entró al informe.
6. **Límites.** Lo que la cifra no permite afirmar.

La regla del proyecto es que el informe y los dashboards se lean sin conocimiento técnico, y que todo lo técnico esté aquí. Si una afirmación del informe no tiene respaldo en este documento, es un error del documento, no una licencia del informe.

Los archivos citados entre acentos graves —`ranking_marcas.csv`, por ejemplo— están en la carpeta `tablas/` de la edición y se pueden abrir directamente.

2. El estudio

2.1. Alcance y fuentes

Edición **2024**. Se procesan las entregas SPSS originales del proveedor y el listado anual de marcas. Se conservan los instrumentos y publicaciones de origen. Una edición no produce resultados hasta contar con una entrega válida.

La encuesta es **transversal**: preferencias y percepciones provienen de las mismas personas y del mismo momento. El panel entre ediciones sigue **marcas**, no personas. Ni las asociaciones, ni las regresiones con efectos fijos, ni los escenarios identifican efectos causales.

Los intervalos expresan variación condicional a la muestra. No corrigen selección del panel, no respuesta, cobertura ni diferencias no observadas entre olas. La base no incorpora un diseño probabilístico con ponderadores documentados; los resultados **no deben presentarse como inferencia de diseño a toda la población de Chile**.

2.2. El diseño de exposición: quién ve qué

Esta sección es la más importante del apéndice, porque de ella dependen todos los denominadores del estudio. **Nadie responde por todas las marcas**. El cuestionario filtra dos veces.

2.2.1. Filtro 1: una industria por persona

En P0 la persona declara de cuáles de las cuatro industrias es usuaria. El cuestionario le **sorteo una sola** entre las que declaró, y la registra en la variable RECO_TARGET. A partir de ahí, todas las baterías de marca —conocimiento (P9), preferencia (P10), compra habitual (P11) y atributos (P12)— se le muestran **únicamente para las marcas de esa industria**.

La entrega del proveedor exporta las columnas de las otras industrias como ceros, no como valores faltantes. Leídas sin cuidado, esas celdas parecen decir «no conoce la marca» cuando en realidad dicen «nunca se le preguntó». El pipeline lo verifica explícitamente y se detiene si encuentra una sola declaración de conocimiento fuera de la industria asignada.

Tabla 1: Personas expuestas a las marcas de cada industria

Industria	Marcas en el listado	Personas expuestas
Aseguradoras	29	388
Retail	28	388
Servicios esenciales	29	394
Servicios financieros	27	389

Consecuencia directa. El denominador de «cuántos conocen la marca X» no es la muestra, sino las personas asignadas a la industria de X: alrededor de un cuarto del total. Usar la muestra completa divide por cuatro todas las cifras de alcance y las vuelve incomparables con cualquier otra fuente de mercado.

2.2.2. Filtro 2: hasta quince marcas en la batería de atributos

De las marcas que la persona declara conocer, el cuestionario le pide evaluar los 25 atributos para **hasta quince**. El proveedor deja registrado cuáles fueron, en un formato que cambia de una edición a otra: OPCION_MOSTRADA_1..15, una columna por marca, en 2024 y 2025; o MARCAS_EVAL, los códigos separados por comas, en 2023 y 2026. El pipeline lee los dos y se detiene si no encuentra ninguno, porque sin ese registro los puntajes quedarían con el denominador equivocado.

El sorteo **no es parejo**: prioriza a las marcas menos conocidas, de modo que todas terminen con una base de evaluación parecida —cercana a doscientas personas—. A una marca muy conocida se le pregunta a poco más de la mitad de quienes la conocen; a una de nicho, a todas.

Tabla 2: Cobertura de la batería de atributos: de quienes conocen la marca, a cuántos se les preguntó

Mar- cas	Conocedores, mediana	Evaluadores, mediana	Cobertura mínima	Cobertura mediana	Cobertura máxima
113	279	196	0.54	0.7	1

Consecuencia directa. El denominador del puntaje de un atributo no son los conocedores, sino los **evaluadores**: las personas a las que se les mostró la marca en P12 y por lo tanto tuvieron la oportunidad de asociarle algo. Dividir por los conocedores le cobra a las marcas grandes las preguntas que nunca se les hicieron, y lo hace justamente en proporción a su tamaño.

2.2.3. Controles de diseño

`1_limpieza_datos.R` se detiene si alguna de estas tres condiciones falla:

Condición	Qué significaría que falle
Ninguna declaración de conocimiento fuera de la industria asignada	El supuesto de una industria por persona es falso
Toda marca mostrada en P12 es una marca conocida	El registro de exposición no corresponde a este cuestionario
Toda marca con atributos asociados fue mostrada en P12	Hay asociaciones sin pregunta que las origine

En la edición 2024 las tres se cumplen sin excepciones.

2.2.4. Qué queda pendiente en este bloque

Los dos filtros describen **quién pudo responder**. Que el denominador sea el correcto no garantiza que ese conjunto de personas represente a la población de interés: esa es una pregunta distinta, y se trata en la Sección 2.3.

2.3. Ponderación: dos correcciones que se multiplican

Cada persona entra a los resultados con un peso, y ese peso es el producto de dos correcciones que arreglan problemas distintos:

$$w_i = \underbrace{m_i}_{\text{muestral}} \times \underbrace{e_i}_{\text{exposición}}$$

El **ponderador muestral** m_i lleva a la muestra a parecerse a la población chilena. El **ponderador de exposición** e_i lleva a los asignados a una industria a parecerse a quienes la usan. El primero lo entrega el proveedor; el segundo se estima aquí, porque el diseño del cuestionario lo hace necesario y nadie lo documenta.

Las dos secciones que siguen tratan cada uno por separado.

2.3.1. El ponderador muestral

Esta edición (2024) **no** viene ponderada: el proveedor no entregó ponderador y todas las personas pesan igual. Lo que sigue describe el procedimiento para las ediciones que sí lo traen.

La muestra se levanta por cuotas de sexo, tramo de edad, grupo socioeconómico y región, así que parte cerca de la composición del país; pero las cuotas se llenan con lo que el panel entrega, y quedan desviaciones. Desde 2026 el proveedor entrega un ponderador de **post-estratificación por celda**: dentro de cada combinación de

sexo $\times$ tramo de edad $\times$ GSE $\times$ región, todas las personas reciben el mismo peso, calculado para que el total de la celda reproduzca su tamaño poblacional.

Se normaliza a media 1, de modo que la suma de los pesos sea el número de casos y toda base ponderada se lea en la misma unidad que una sin ponderar. Esa normalización no cambia ningún porcentaje: todos son cocientes de sumas ponderadas.

Qué no hace. Un ponderador de post-estratificación corrige la composición observable de la muestra; no corrige que quienes aceptan participar en un panel online difieran de quienes no lo hacen en algo que no esté capturado por esas cuatro variables. Eso queda fuera del alcance de cualquier ponderador y se declara como límite, no como supuesto.

2.3.1.1. Ediciones ponderadas y no ponderadas en una misma serie

Las entregas de 2023, 2024 y 2025 no traen ponderador: en ellas $m_i = 1$ para todo el mundo, que es exactamente como se calcularon sus resultados publicados. Desde 2026 sí lo hay.

Eso deja una serie en que una edición está ponderada y las anteriores no, y conviene ser explícito sobre lo que implica. La alternativa —renunciar al ponderador de 2026 para preservar la simetría— empeoraría la edición nueva para que se pareciera a las viejas, que es el peor de los dos intercambios: se perdería precisión poblacional hoy a cambio de una comparabilidad aparente.

Dos cosas acotan el problema. La primera es que las cuotas del terreno son las mismas todos los años, así que la muestra sin ponderar ya parte cerca de la composición objetivo: la corrección que introduce el ponderador es de pocos puntos, no de órdenes de magnitud. La segunda es que la comparación entre ediciones que más se usa —quién subió y quién bajó en el ranking— se apoya en diferencias dentro de la misma edición, donde el ponderador afecta a las dos marcas comparadas por igual.

Con todo, **un cambio pequeño entre 2025 y 2026 en un indicador de opinión puede deberse en parte al ponderador y no a un cambio real**, y así se lee: el análisis longitudinal señala como movimiento solo lo que supera el margen de las dos ediciones.

2.3.2. Ponderación por la inversa de la probabilidad de exposición

Los dos filtros de la Sección 2.2 no solo cambian el denominador: también cambian **quién** está en él. Esta parte trata ese segundo problema, que es distinto y se corrige de otra forma.

2.3.2.1. Los dos mecanismos, examinados por separado

Cada filtro podría sesgar, y cada uno se examinó antes de corregir nada. La regla fue: una corrección solo se aplica si se demuestra que hace falta.

2.3.2.1.1. El tope de quince marcas: no sesga

El sorteo de las quince marcas prioriza a las menos conocidas, así que la probabilidad de que a alguien se le muestre una marca depende de la marca y de cuántas marcas conoce esa persona. Eso sesgaría el puntaje solo si, además, **cuántas marcas conoce predijera cómo marca atributos**.

No lo hace. Con efectos fijos de marca, el número de marcas conocidas no predice cuántos atributos asocia la persona:

Desenlace	Coefficiente por marca conocida adicional	p
Atributos marcados (de 25)	0,0012	0,87
Asocia «Es cercana» (log-odds)	−0,0047	0,17
Asocia «Es tecnológica» (log-odds)	0,0023	0,44

Sin efectos fijos sí aparece un patrón, pero es **composición de marcas**: quien conoce pocas marcas ve sus pocas marcas —masivas, muy asociadas—, y quien conoce muchas recibe una rotación que incluye marcas

de nicho, con tasas de asociación bajas. Los efectos fijos absorben eso por completo; el R^2 no se mueve en la cuarta cifra decimal al agregar el predictor.

Es exactamente la condición de ignorabilidad que una ponderación repararía. Como se cumple, el estimador sin ponderar dentro de cada marca ya es insesgado y **no se pondera por este mecanismo**. Ponderar aquí solo costaría precisión.

2.3.2.1.2. La asignación de industria: sí sesga

Este es distinto. La asignación no es un sorteo parejo entre las industrias que la persona usa: el cuestionario reparte buscando llenar cuotas parecidas por industria. Una industria con pocos usuarios se lleva una fracción alta de ellos; una con muchos, una fracción baja.

La consecuencia es que quienes usan **una sola** industria quedan sobrerrepresentados justo en las industrias más masivas, porque no compiten con nadie por su asignación.

Tabla 3: Composición de los asignados frente a la de los usuarios

Industria	Usua- rios	Asigna- dos	Industrias que usa: usuarios	Industrias que usa: asignados	Pondera- do
Servicios financieros	1105	389	3.38	2.98	3.33
Retail	1134	388	3.27	2.74	3.34
Aseguradoras	778	388	3.63	3.41	3.62
Servicios esenciales	1373	394	3.03	2.14	3.02

Y usar más industrias **sí** predice conocer más marcas: con efectos fijos de industria, cada industria adicional se asocia con conocer 1,76 marcas más ($p \approx 3 \times 10^{-23}$). También predice cómo se marcan los atributos, aunque de forma asimétrica: afecta a «Es cercana» ($p \approx 7 \times 10^{-13}$) y no a «Es tecnológica» ($p = 0,93$).

Están las dos condiciones del sesgo —selección desigual y una variable que predice el resultado— así que aquí la corrección sí corresponde.

2.3.2.2. Cómo se estima la probabilidad

La probabilidad de asignación no viene documentada en la entrega, así que se estima del propio dato con una **regresión logística condicional**: el menú de cada persona son las industrias que declara usar, la elegida es la que le tocó, y lo único que entra al modelo son constantes por industria.

$$\Pr(\text{asignada} = g \mid \text{usa } U_i) = \frac{\exp(\alpha_g)}{\sum_{h \in U_i} \exp(\alpha_h)}$$

Tres parámetros libres para cuatro industrias. Es la forma más simple que respeta la restricción de que las probabilidades sumen uno dentro del menú, y reproduce por construcción el total de asignados de cada industria. El peso de cada persona es $w_i = 1/\hat{\pi}_i(g_i)$.

Es una propensión estimada, no una probabilidad de diseño conocida. El algoritmo real del proveedor es probablemente un llenado de cuotas determinista; lo que se modela es su comportamiento marginal. Por eso la validación de abajo no es un formalismo: es lo único que sostiene la corrección.

2.3.2.3. Validación

Si los pesos están bien, tienen que reconstruir la población de usuarios. Dos pruebas:

Tabla 4: Los pesos reconstruyen la base de usuarios

Industria	Usuarios declarados	Suma de los pesos	Desvío %	Efecto de diseño	Casos efectivos
Servicios financieros	1105	1086	-1.7	1.16	334
Retail	1134	1177	3.8	1.30	299
Aseguradoras	778	776	-0.3	1.05	371
Servicios esenciales	1373	1350	-1.7	1.61	245

1. **La suma de los pesos de los asignados a una industria reconstruye el número de personas que declaran usarla**, con un desvío menor al 2 %.
2. **La composición ponderada coincide con la de los usuarios**: en la tabla anterior, Servicios esenciales pasa de 2,08 industrias usadas en promedio (sin ponderar) a 3,00 (ponderado), frente a 3,03 que es el valor real entre sus usuarios.

Ambas están entre los controles automáticos de **auditoria/comprobar.R**: si el desvío supera el 10 % o la composición se aleja más de 0,25 industrias, la corrida falla.

2.3.2.4. Qué se pondera y qué no

Cantidad	Peso que usa	Por qué
% que conoce, compra, prefiere	Muestral $\times$ exposición	El estimando es «de los usuarios de la industria», en la población
Puntaje de un atributo, Índice	Muestral $\times$ exposición	La selección de personas afecta también a cómo se marca
Perfiles y territorios de marca	Muestral $\times$ exposición	Se construyen desde los puntajes
Importancia declarada, indicadores de contexto, perfil	Solo muestral	Las preguntas generales (P0 a P8 y P17 en adelante) se le hacen a toda la muestra: no pasan por el filtro de industria
Modelos de elección (logit condicional)	Muestral $\times$ exposición	Comparan a la persona consigo misma, así que la selección no confunde la comparación; el peso decide cuánto pesa cada persona en el promedio de esas comparaciones
Estructura de los atributos (correlaciones tetracóricas, análisis factorial)	Ninguno	Describe cómo se acompañan los atributos entre sí, no una cifra de la población; las rutinas usadas no admiten pesos

El estimador de los puntajes es de **Hájek** —cociente de sumas ponderadas—, no de Horvitz-Thompson:

$$\hat{p}_{ba} = \frac{\sum_i w_i M_{ib} X_{iba}}{\sum_i w_i M_{ib}}.$$

Al normalizar por la suma de los pesos observados y no por su total teórico, el puntaje no depende de la escala de los pesos y es mucho más estable cuando la base es chica.

2.3.2.5. Lo que cuesta: precisión

Ponderar siempre cuesta precisión. El efecto de diseño $1 + CV^2(w)$ va de 1,04 a 1,66 según la industria, de modo que una marca con doscientos evaluadores puede tener la precisión de ciento veinte.

Por eso el umbral de base pasa a aplicarse sobre los casos efectivos,

$$n_{\text{ef}} = \frac{(\sum_i w_i M_{ib})^2}{\sum_i w_i^2 M_{ib}},$$

y no sobre el recuento de evaluadores. Una marca entra al ranking con al menos 60 casos efectivos. El criterio es más exigente que antes y deja fuera a alguna marca que sí entraba.

Los intervalos también cambian: con ponderadores, el intervalo de Wilson ya no aplica —supone un conteo binomial y aquí el puntaje es un cociente de sumas ponderadas—, así que se usa el error de linealización, el mismo con que se calculan las brechas. Wilson sobre los casos efectivos queda solo como respaldo para las celdas donde todos responden igual y la linealización daría error cero.

2.3.2.6. Cuánto cambian los resultados

Tabla 5: Efecto de ponderar sobre el alcance

Industria	Marcas	Cambio medio (pp)	Cambio mediano (pp)	Cambio máximo (pp)
Aseguradoras	29	1.67	1.47	2.52
Retail	28	1.10	0.95	4.23
Servicios esenciales	29	5.73	5.84	10.78
Servicios financieros	27	2.57	2.59	5.97

El cambio es siempre al alza —ponderar devuelve el peso a los usuarios intensivos, que conocen más marcas— y se concentra en Servicios esenciales, que era la industria con peor composición.

Tabla 6: Efecto de ponderar sobre el ranking

Marcas	Cambio de puesto, mediana	Cambio de puesto, promedio	Cambio máximo	No se mueven
109	3	3.7	20	6

Tabla 7: Las marcas que más se mueven al ponderar

Marca	Industria	Puesto sin ponderar	Puesto ponderado	Sube	Índice sin ponderar	Índice ponderado
Chek	Servicios financieros	80	60	20	12.6	15.0
Lipigas	Servicios esenciales	35	23	12	20.3	23.9
Latam	Servicios esenciales	49	39	10	17.6	20.1
BCI	Servicios financieros	73	63	10	13.6	14.7
Pedidos Ya	Servicios esenciales	34	26	8	20.6	23.0
Spid	Retail	84	76	8	11.6	13.0
Cabify	Servicios esenciales	74	82	-8	13.3	12.3
Pronto	Retail	39	49	-10	19.5	17.6

Marca	Industria	Puesto sin ponderar	Puesto ponderado	Sube	Índice sin ponderar	Índice ponderado
Starken	Servicios esenciales	69	81	-12	14.1	12.4
Claro	Servicios esenciales	48	65	-17	17.8	14.6
Abastible	Servicios esenciales	59	79	-20	15.9	12.9

El titular no cambia; la tabla media sí. Las primeras posiciones se mueven a lo sumo un par de lugares. Los movimientos grandes se concentran en Servicios esenciales, que es donde el sesgo de composición era mayor, y ahí llegan a más de veinte puestos.

2.3.2.7. Límites de esta corrección

- **La propensidad es estimada.** Si el algoritmo del proveedor dependiera de algo más que el conjunto de industrias usadas —el orden de llegada, por ejemplo—, el modelo lo captaría solo en promedio. La validación de la composición es el respaldo disponible, no una garantía.
- **Corrige composición observada, no selección no observada.** Los pesos igualan la distribución de industrias usadas. No corrigen que quien contesta un panel online difiera de quien no lo hace.
- **No se corrige la no respuesta ni la cobertura.** Sigue sin haber ponderadores de expansión a la población de Chile, y los resultados siguen sin ser inferencia de diseño.
- **El tope de quince queda sin ponderar a propósito.** La prueba de arriba dice que no hace falta. Si en una edición futura esa prueba fallara, habría que ponderar también por ese mecanismo; el control está escrito para que se note.

2.4. Limpieza y población de análisis

Se identifican las preguntas por sus nombres originales: P9 para conocimiento, P10 para orden de preferencia, P11 para compra y P12 para asociaciones. Los identificadores de persona se asignan **después** de aplicar las exclusiones registradas, de modo que ninguna tabla quede desalineada respecto de la base cruda.

Las exclusiones provienen de la entrega depurada del proveedor —la versión «sin outliers»— y se anotan una sola vez en `casos_excluidos.csv`. El criterio original mezcla revisiones manuales que no se pueden reproducir; por eso se conserva la lista en vez de intentar recalcularla.

Cada observación de percepción representa una combinación persona-marca-atributo. Una asociación no marcada se codifica como cero **únicamente dentro del conjunto de marcas mostradas** a esa persona. Se comprueba que no existan duplicados de persona-marca-atributo, que cada preferencia sea coherente con el menú y que los catálogos cubran los códigos observados. Los códigos especiales, como «Ninguna», se excluyen del universo de marcas.

Las tasas de las preguntas generales usan respuestas válidas a cada pregunta, y esas preguntas sí se le hacen a toda la muestra. P1 se resume con respuestas de 5 a 7; P3 con respuestas de 7 a 10; P17 y P20 con respuestas de 4 a 5; P19 considera uso mensual o más frecuente (códigos 4 a 6). P6 distingue explícitamente interés sin costo adicional de aceptación de más tiempo y/o dinero.

Los recuentos por alternativa no deben confundirse con el denominador de la pregunta. El pipeline conserva las etiquetas y bases para auditar cada indicador.

2.5. Perfil de la muestra

Tabla 8: Composición de la muestra

variable	categoría	n	porcenta- je	porcenta- je_muestra	base_pre- gunta
Genero	Hombres	762	48.9	48.9	1559
Genero	Mujeres	797	51.1	51.1	1559
GSE	AB	27	1.7	1.7	1559
GSE	C1a	148	9.5	9.5	1559
GSE	C1b	238	15.3	15.3	1559
GSE	C2	327	21.0	21.0	1559
GSE	C3	488	31.3	31.3	1559
GSE	D	331	21.2	21.2	1559
Region	I Región de Tarapacá	65	4.2	4.2	1559
Region	II Región de Antofagasta	75	4.8	4.8	1559
Region	III Región de Atacama	66	4.2	4.2	1559
Region	IV Región de Coquimbo	71	4.6	4.6	1559
Region	IX Región de La Araucanía	142	9.1	9.1	1559
Region	V Región de Valparaíso	205	13.1	13.1	1559
Region	VI Región del Libertador General Bernardo O'Higgins	74	4.7	4.7	1559
Region	VII Región del Maule	80	5.1	5.1	1559
Region	VIII Región del Bío Bío	117	7.5	7.5	1559
Region	X Región de los Lagos	104	6.7	6.7	1559
Region	XI Región de Aysén del General Carlos Ibañez del Campo	14	0.9	0.9	1559
Region	XII Región de Magallanes y la Antártica Chilena	30	1.9	1.9	1559
Region	XIII Región Metropolitana	315	20.2	20.2	1559
Region	XIV Región Los Ríos	100	6.4	6.4	1559
Region	XV Arica y Parinacota	30	1.9	1.9	1559
Region	XVI Ñuble	71	4.6	4.6	1559
Tramo de edad	18_24	220	14.1	14.1	1559
Tramo de edad	25_34	306	19.6	19.6	1559
Tramo de edad	35_44	313	20.1	20.1	1559
Tramo de edad	45_54	310	19.9	19.9	1559
Tramo de edad	55_64	217	13.9	13.9	1559
Tramo de edad	65_75	193	12.4	12.4	1559

La muestra se levanta con cuotas de sexo, edad, grupo socioeconómico y región. No se aplican ponderadores de expansión. Las cifras describen a las personas entrevistadas; su traslado a la población es una extrapolación que el diseño no respalda formalmente.

2.6. Denominadores: qué cambió respecto de ediciones anteriores

Hasta la revisión documentada en este apéndice, el pipeline usaba dos denominadores incorrectos:

Cantidad	Denominador anterior	Denominador correcto
% que conoce la marca	Muestra completa	Personas asignadas a la industria de la marca
Puntaje de un atributo	Personas que conocen la marca	Personas a las que se les mostró la marca en P12
Índice EmpatIA	Personas que conocen la marca	Personas a las que se les mostró la marca
Share de primera preferencia	Muestra completa	Personas asignadas a la industria de la marca
Perfil de una persona	Marcas que conoce	Marcas que evaluó

A eso se suma una tercera corrección, de naturaleza distinta: los asignados a una industria no son una muestra representativa de quienes la usan, y se corrige ponderando por la inversa de la probabilidad de asignación. La Sección 2.3 lo documenta.

El primer error **subestima** todas las cifras de alcance por un factor cercano a cuatro, de manera pareja. El segundo **no** es parejo: castiga a las marcas más conocidas en proporción a su cobertura, que es justamente donde el sorteo recorta más. Por eso corregirlo reordena el ranking y no solo lo reescala.

Tabla 9: Efecto de la corrección sobre el ranking publicado

Marcas en el ranking	Cambio de puesto, mediana	Cambio de puesto, promedio	Cambio máximo	Marcas que no se mueven
109	10	11.9	29	2

Tabla 10: Las diez marcas que más se mueven al corregir el denominador

Marca	Industria	Puesto antes	Puesto ahora	Sube	Cobertura	Evalua- dores	Conocedo- res
Seguros Falabella	Aseguradoras	62	37	25	0.55	166	300
Itaú Corpbanca	Servicios financieros	36	59	-23	0.98	196	201
La Araucana	Servicios financieros	67	90	-23	0.99	179	181
Cencopay	Servicios financieros	11	35	-24	0.99	149	150
Tapp	Servicios financieros	17	43	-26	0.98	118	120
Compraqui	Servicios financieros	21	47	-26	1.00	121	121
Bupa	Aseguradoras	13	40	-27	0.99	133	134
Santa María	Aseguradoras	44	71	-27	0.97	143	147
Chek	Servicios financieros	32	60	-28	1.00	104	104
Spid	Retail	48	76	-28	0.98	92	94
Cabify	Servicios esenciales	53	82	-29	0.98	168	172

La columna «cobertura» explica el movimiento por completo: es la fracción de conocedores a quienes efectivamente se les preguntó. Las marcas con cobertura cercana a 1 —las de nicho— no estaban siendo castigadas

y por eso ahora bajan en términos relativos; las de cobertura cercana a 0,5 —las más conocidas— estaban perdiendo la mitad de su puntaje y ahora lo recuperan.

Qué hacer con los resultados ya presentados. Las cifras publicadas antes de esta corrección no son comparables con las actuales. La reconciliación marca por marca está en la tabla anterior y en `ranking_marcas.csv`, que conserva `conocimiento` y `evaluadores` en columnas separadas para poder rehacer cualquiera de las dos versiones.

3. Qué esperan las personas de una marca

3.1. Importancia declarada de los atributos

Qué muestra el informe. Un índice de 0 a 100 por atributo, que ordena qué esperan las personas de una marca antes de mirar marca alguna.

Cómo se calcula. Dos preguntas miden lo mismo por caminos distintos y se reportan juntas:

- **P7** pide calificar cada uno de los atributos de 1 a 7. Se promedia y se reescala: índice = $100(\bar{x} - 1)/6$.
- **P8** obliga a elegir los tres más importantes. Se reporta el porcentaje de personas que pone el atributo entre esos tres.

P7 discrimina poco: casi todo resulta importante cuando no hay que renunciar a nada. P8 es la que separa prioridades de buenas intenciones. El orden publicado usa P7; P8 acompaña como verificación del trade-off.

Ambas preguntas se le hacen a **toda la muestra**, de modo que aquí no opera el filtro de exposición de la Sección 2.2 y el denominador es simplemente el número de respuestas válidas.

Tabla 11: Importancia declarada de los atributos

Atributo	Bloque	Promedio 1 a 7	Índice 0 a 100	Entre los tres (%)
Sus transacciones son seguras	Empa- tIA	6.52	92.0	36.2
Se hace cargo de sus errores	Empa- tIA	6.35	89.2	20.2
Soluciona de manera efectiva mis problemas	Empa- tIA	6.32	88.6	31.2
Es honesta y transparente	Humani- dad	6.30	88.3	23.4
Es fácil de contactar	Empa- tIA	6.21	86.9	16.9
Su atención y/o servicio es ágil	Tecnolo- gia	6.16	86.0	20.7
Su sitio web y/o aplicación son de uso fácil e intuitivo	Tecnolo- gia	6.13	85.6	17.4
Es amable en el trato	Humani- dad	6.13	85.4	11.7
Se pone en mi lugar cuando tengo un problema	Humani- dad	6.05	84.2	13.5
Reconoce la antigüedad de nuestra relación siendo su cliente	Humani- dad	6.04	84.0	13.4
Toma en cuenta y se adapta a las contingencias (ej: pandemia)	Humani- dad	5.99	83.1	4.5
Tiene presencia en todo Chile	Empa- tIA	5.87	81.2	14.3
Me permite contactarla a través de personas reales (ej: un ejecutivo)	Humani- dad	5.86	81.1	15.4
Usa mi mismo lenguaje	Humani- dad	5.74	79.1	5.5
Se preocupa genuinamente de mi	Humani- dad	5.71	78.5	6.0
Se mantiene actualizada y a la vanguardia tecnológica	Tecnolo- gia	5.71	78.4	9.2
Me ofrece servicios, productos y/o beneficios personalizados	Empa- tIA	5.70	78.3	10.5

Atributo	Bloque	Promedio 1 a 7	Índice 0 a 100	Entre los tres (%)
Me hace sentir comprendido	Humani- dad	5.69	78.1	3.5
Innova constantemente en sus productos y/o servicios	Tecnolo- gía	5.58	76.4	6.6
Comparte mis valores y principios	Humani- dad	5.43	73.9	4.8
Sus procesos son automatizados	Tecnolo- gía	5.41	73.4	3.7
Me regalonea y se preocupa de los detalles	Humani- dad	5.36	72.7	4.7
Tiene un diseño moderno	Tecnolo- gía	5.14	68.9	3.3

3.2. La misma pregunta dentro de cada público

Resultado adicional. El informe publica el orden del total. La tabla completa por público está en `importancia_segmentos.csv` y alimenta el dashboard público.

Tabla 12: Los cinco atributos más importantes en cada público

Público	Puesto	Atributo	Índice
45 o mas (Generacion)	1	Sus transacciones son seguras	92.5
45 o mas (Generacion)	2	Se hace cargo de sus errores	90.0
45 o mas (Generacion)	3	Soluciona de manera efectiva mis problemas	89.4
45 o mas (Generacion)	4	Es honesta y transparente	89.2
45 o mas (Generacion)	5	Es fácil de contactar	87.7
ABC1 (GSE)	1	Sus transacciones son seguras	93.1
ABC1 (GSE)	2	Se hace cargo de sus errores	91.4
ABC1 (GSE)	3	Es honesta y transparente	91.1
ABC1 (GSE)	4	Soluciona de manera efectiva mis problemas	91.0
ABC1 (GSE)	5	Es fácil de contactar	89.1
C2 (GSE)	1	Sus transacciones son seguras	91.9
C2 (GSE)	2	Soluciona de manera efectiva mis problemas	89.3
C2 (GSE)	3	Se hace cargo de sus errores	88.7
C2 (GSE)	4	Es honesta y transparente	88.0
C2 (GSE)	5	Es fácil de contactar	86.1
C3 (GSE)	1	Sus transacciones son seguras	91.4
C3 (GSE)	2	Se hace cargo de sus errores	88.4
C3 (GSE)	3	Soluciona de manera efectiva mis problemas	87.4
C3 (GSE)	4	Es honesta y transparente	86.8
C3 (GSE)	5	Es fácil de contactar	85.4
D/E (GSE)	1	Sus transacciones son seguras	91.5
D/E (GSE)	2	Se hace cargo de sus errores	88.3
D/E (GSE)	3	Es honesta y transparente	87.5
D/E (GSE)	4	Es fácil de contactar	87.0
D/E (GSE)	5	Soluciona de manera efectiva mis problemas	86.8
Hombres (Genero)	1	Sus transacciones son seguras	90.5
Hombres (Genero)	2	Se hace cargo de sus errores	88.3
Hombres (Genero)	3	Soluciona de manera efectiva mis problemas	87.7
Hombres (Genero)	4	Es honesta y transparente	87.3
Hombres (Genero)	5	Es fácil de contactar	85.1

Público	Puesto	Atributo	Índice
Menores de 45 (Generacion)	1	Sus transacciones son seguras	91.5
Menores de 45 (Generacion)	2	Se hace cargo de sus errores	88.6
Menores de 45 (Generacion)	3	Soluciona de manera efectiva mis problemas	88.0
Menores de 45 (Generacion)	4	Es honesta y transparente	87.6
Menores de 45 (Generacion)	5	Es fácil de contactar	86.2
Mujeres (Genero)	1	Sus transacciones son seguras	93.4
Mujeres (Genero)	2	Se hace cargo de sus errores	90.2
Mujeres (Genero)	3	Soluciona de manera efectiva mis problemas	89.5
Mujeres (Genero)	4	Es honesta y transparente	89.4
Mujeres (Genero)	5	Es fácil de contactar	88.5
Total (Total)	1	Sus transacciones son seguras	92.0
Total (Total)	2	Se hace cargo de sus errores	89.2
Total (Total)	3	Soluciona de manera efectiva mis problemas	88.6
Total (Total)	4	Es honesta y transparente	88.3
Total (Total)	5	Es fácil de contactar	86.9

Cómo leerlo. Se comparan **puestos** y no niveles. Hay públicos que califican todo más alto que otros, y esa diferencia de estilo de respuesta no es una diferencia de prioridades.

Límite. Los públicos se solapan: una misma persona está en «Mujeres» y en «ABC1» a la vez. Una diferencia entre dos niveles de una segmentación no controla por las otras.

3.3. Expectativa de equilibrio y disposición a pagar

Qué muestra el informe. Que una mayoría amplia considera importante que las marcas equilibren cercanía y tecnología, y qué proporción declara estar dispuesta a pagar por ello.

Cómo se calcula. Cada indicador es un porcentaje sobre las respuestas válidas de su pregunta, con los cortes documentados más arriba. La tabla `kpis_informe.csv` guarda para cada indicador su variable de origen, su porcentaje y su base, de modo que cualquier cifra del informe se pueda rastrear hasta la pregunta.

Tabla 13: Indicadores de contexto, con su pregunta de origen y su base

Indicador	Pregun- ta	%	Base
Espera marcas tecnologicas	P1_1	75.8	1559
Espera marcas cercanas	P1_2	85.9	1559
Prefiere marcas tecnologicas	P2	36.9	1559
Prefiere marcas cercanas	P2	63.1	1559
Importante balancear cercania y tecnologia	P3	82.6	1559
No esta dispuesto a pagar	P6	11.2	1559
Paga si no le cuesta mas	P6	73.1	1559
Paga incluso si le cuesta mas	P6	15.7	1559
Dispuesto a pagar	P6	88.8	1559
Los sistemas automatizados son eficientes en la resolución de problemas o consultas	P17_1	33.3	1559
Los sistemas automatizados pueden tener la empatía o comprensión que tienen los humanos	P17_2	15.7	1559
Hay situaciones en que los seres humanos son insustituibles en la atención al cliente	P17_3	83.1	1559
Me da miedo que los robots terminen reemplazando a los humanos en el futuro	P17_4	42.2	1559
La inteligencia artificial no tiene sentido sin ser complementada con inteligencia humana	P17_5	73.6	1559
Mi nivel de confianza en la Inteligencia Artificial ha aumentado en los últimos 12 meses	P17_6	37.4	1559

Límite. La disposición a pagar es declarativa y sin costo real. Sobreestima sistemáticamente la disposición efectiva; se reporta como orden de magnitud y como comparación entre ediciones, no como elasticidad.

3.4. Actitud frente a la inteligencia artificial

Qué muestra el informe. Cuatro láminas: qué piensan de la IA, qué les preocupa, cómo prefieren ser atendidos y qué asistentes conocen y usan.

Cómo se calcula. P17 y P20 comparten escala de 1 a 5 y se reportan como «top 2» —las dos categorías más altas—. P21 y P23 son de respuesta única y se reportan como distribución completa. P18 es conocimiento (marca / no marca) y P19 es frecuencia de uso, con usuario definido desde «un par de veces al mes» (código 4).

Límite. Son preguntas de actitud declarada sobre una tecnología en cambio rápido. La comparación entre ediciones es informativa; el nivel absoluto depende de cómo estaba la conversación pública en el momento del trabajo de campo.

3.5. El bloque de inteligencia artificial, cifra por cifra

Las preguntas P18 a P27 se analizan aparte, en `prensa_ia.R`, porque se citan fuera del informe —en prensa y en presentaciones— y ahí una cifra sin su base y sin su margen se vuelve una afirmación que el estudio no sostiene. La tabla `kpis_ia_prensa.csv` deja cada indicador con cinco columnas que lo acompañan siempre: sobre qué base se calculó, cuántos casos tiene, cuántos casos efectivos, y entre qué valores cae razonablemente.

3.5.1. Los denominadores, que no son todos el mismo

Es la trampa de este bloque. **P18** —qué asistentes conoce— se le pregunta a todas las personas. **P19** —con qué frecuencia lo usa— solo se le pregunta a quien declaró conocerlo. De ahí que «usa ChatGPT» pueda significar dos cosas:

Cifra	Denominador	Qué mide
Uso sobre la población	Toda la muestra	Penetración: de cada cien personas, cuántas lo usan
Uso entre quienes lo conocen	Solo quienes declaran conocerlo	Conversión: de cada cien que saben que existe, cuántas lo usan

Las dos se publican, con nombre distinto, en `prensa_asistentes.csv`. Quien no conoce el asistente no contestó P19: su «no usa» es una consecuencia del filtro del cuestionario y no una respuesta suya, así que al construir la penetración se cuenta como no usuario y al construir la conversión queda fuera del denominador.

Se considera usuario a quien declara usar el asistente **al menos un par de veces al mes** (4 o más en la escala de P19). Es un umbral de uso incorporado, no de haber probado.

3.5.2. Los índices derivados

Tres indicadores no salen de una pregunta sino de combinar varias, y conviene tener la definición a mano:

Indicador	Definición
Usa al menos un asistente	Usa, al menos un par de veces al mes, alguno de los asistentes listados
Preocupado por la IA	Declara preocupación alta (4 o 5) en la mitad o más de los riesgos de P20
Se endurece con el canal	Acepta un canal no humano para el trámite (P21) y exige una persona ante un problema (P23)

El umbral de «preocupado» se fijó en la mitad de los ítems y no en uno solo a propósito: con seis u ocho riesgos consultados, marcar alto en cualquiera es casi universal y no distingue a nadie. Lo que interesa es el patrón.

3.5.3. El margen de cada cifra

Cada porcentaje se acompaña de su intervalo al 95 %, calculado con la fórmula binomial sobre los **casos efectivos** y no sobre los casos a secas:

$$n_{\text{ef}} = \frac{(\sum_i m_i)^2}{\sum_i m_i^2}, \quad \text{margen} = 1,96 \sqrt{\frac{\hat{p}(1 - \hat{p})}{n_{\text{ef}}}}$$

donde m_i es el ponderador muestral de la persona. Usar los casos sin descontar lo que cuesta ponderar declararía una precisión que ya se gastó.

3.5.4. Los cortes

Cada indicador se abre por género, generación (menores de 45 y 45 o más), GSE y tramo de edad. **Región no entra:** dieciséis niveles sobre mil quinientos casos dejan celdas que no sostienen ninguna afirmación. Con seis tramos de edad las celdas quedan cerca de 250 casos, lo que da un margen aproximado de ± 6 puntos: una diferencia menor entre dos tramos no se afirma.

4. El ranking

4.1. Índice, atributos y dimensiones

Cómo se calcula. Para cada marca b y atributo a :

$$\hat{p}_{ba} = \frac{\sum_i w_i M_{ib} X_{iba}}{\sum_i w_i M_{ib}},$$

donde $M_{ib} = 1$ si a la persona i se le **mostró** la marca b en la batería de atributos, $X_{iba} = 1$ si le asoció el atributo a , y w_i es su peso de exposición (Sección 2.3). Dos cambios respecto de ediciones anteriores: el denominador es M —exposición— y no K —conocimiento—, y las personas entran ponderadas. La Sección 2.6 documenta el primero y la Sección 2.3 el segundo.

El índice de la edición es:

$$I_b = w_C \hat{p}_{b,\text{cercana}} + w_T \hat{p}_{b,\text{tecnologica}}.$$

En esta edición $w_C = 0.525$ y $w_T = 0.475$. Las salidas ejecutivas multiplican por 100.

Advertencia de nomenclatura. El índice **no** promedia los bloques Humanidad y Tecnología como baterías completas: combina dos atributos individuales que llevan esos nombres. Los bloques Humanidad (atributos 1–12), Tecnología (13–19) y EmpatIA (20–25) son clasificaciones conceptuales preexistentes, no factores estimados, y sirven para leer la experiencia, no para construir el índice. Comparten nombre en un caso; no son lo mismo.

Una marca entra al ranking con al menos 60 **casos efectivos** (Sección 2.3). El umbral se aplica sobre lo que determina la precisión: ni los conocedores, que siempre son más, ni el recuento crudo de evaluadores, que ignora el costo de ponderar. Es un umbral operativo: no garantiza precisión, solo descarta lo manifiestamente inestable.

Tabla 14: Peso relativo de cada bloque en la elección (diagnóstico, no ponderadores del índice)

dimension	peso	error	p	peso_relativo	ic_bajo	ic_alto
Tecnología	1.879	0.164	0	0.340	1.557	2.201
Humanidad	1.857	0.289	0	0.336	1.290	2.424
EmpatIA	1.793	0.217	0	0.324	1.367	2.219

El modelo agregado por bloques promedia las respuestas binarias dentro de cada bloque antes de ajustar el logit. Sus coeficientes corresponden a pasar de cero a todos los atributos del bloque, manteniendo los otros constantes. **Dividirlos por su suma no produce** una descomposición de varianza, una probabilidad ni ponderadores equivalentes a la fórmula del índice. La tabla se mantiene para trazabilidad.

4.2. Construcción de los cuatro rankings publicados

Todos usan la misma cantidad I_b y el mismo umbral de base:

- **General:** todas las marcas elegibles, ordenadas por I_b descendente.
- **Por dimensión:** se ordena por $\hat{p}_{b,\text{cercana}}$ para Humanidad y por $\hat{p}_{b,\text{tecnologica}}$ para Tecnología. No se usa el promedio del bloque completo.

- **Por industria:** el mismo orden general, restringido a las marcas de cada rubro.
- **Por categoría:** el mismo orden, restringido a cada categoría. El informe publica el primer lugar; la tabla completa está en `ranking_por_categoria.csv`.

Los empates se resuelven por orden de aparición; con la precisión reportada son infrecuentes.

Un puesto no es una prueba de diferencia. El ranking ordena estimaciones puntuales. Dos marcas contiguas pueden tener intervalos que se solapan por completo, y su orden podría invertirse con otra muestra.

Tabla 15: Ranking general con márgenes del índice

Puesto	Marca	Índice	Desde	Hasta	Evaluadores	Conocedores
1	Mercado Libre	41.5	35.5	47.5	220	347
2	Falabella	39.6	33.7	45.5	217	367
3	Lider	35.8	30.3	41.3	217	372
4	Mercado Pago	34.5	29.1	39.8	230	329
5	Entel	34.4	27.9	40.9	197	362
6	Sodimac	33.7	28.0	39.4	218	365
7	Red Salud	32.3	26.2	38.4	170	288
8	Jumbo	31.8	26.2	37.4	218	372
9	Copec	31.4	24.6	38.3	198	343
10	Movistar	29.9	23.9	35.8	196	347
11	Banco Estado	29.8	24.5	35.1	231	378
12	Tenpo	29.7	24.9	34.5	230	240
13	Wom	27.8	21.5	34.1	198	335
14	Dr. Simi	27.8	22.7	32.8	217	366
15	Mach	26.9	22.3	31.4	229	258
16	Getnet	26.7	20.1	33.3	118	119
17	Ali Express	25.1	20.3	30.0	216	308
18	Uber	25.1	19.3	30.9	198	307
19	Blue Express	24.9	19.5	30.4	199	216
20	Paris	24.4	19.4	29.4	219	364

Tabla 16: Cuántos puestos del top 10 se solapan entre sí

Puesto	Marca	Índice	Se solapa con
1	Mercado Libre	41.5	9
2	Falabella	39.6	9
3	Lider	35.8	9
4	Mercado Pago	34.5	9
5	Entel	34.4	9
6	Sodimac	33.7	9
7	Red Salud	32.3	9
8	Jumbo	31.8	9
9	Copec	31.4	9
10	Movistar	29.9	9

La última columna cuenta con cuántas otras marcas del top 10 el intervalo de esta marca se solapa. Es la lectura honesta del ranking: el orden es informativo en bloques, no posición a posición.

4.3. Incertidumbre de los resultados descriptivos

Las proporciones por atributo usan **intervalos de Wilson** al 95 %, que evitan un margen nulo cuando una proporción es cero o uno:

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}, \quad n = \text{evaluadores.}$$

El índice usa la varianza empírica de la combinación individual $w_C X_C + w_T X_T$, preservando la covarianza entre ambas respuestas en vez de sumar varianzas por separado.

Por qué no basta con la fórmula binomial. Una misma persona evalúa hasta quince marcas. Si es generosa marcando atributos, sube a la vez el puntaje de todas las marcas que evaluó. Tratar cada par persona-marca como independiente subestimaría el margen. El cálculo mantiene juntas todas las respuestas de una misma persona: la influencia de la persona i sobre la proporción de la marca b es

$$u_{ib} = \frac{w_i M_{ib} (X_{ib} - \hat{p}_b)}{\sum_j w_j M_{jb}},$$

y el error se obtiene sumando u_{ib}^2 sobre personas, no sobre pares. Es la linealización del cociente ponderado: ponderar y después usar la fórmula sin ponderar subestimaría el error. Como cada fila del cálculo es una persona completa, la dependencia entre las marcas que ella evalúa queda incorporada sin modelarla explícitamente.

4.4. Las tres referencias: categoría, industria y estudio

Qué cambió. Hasta esta revisión, una marca se comparaba solo contra el promedio de su industria. Ahora se calculan tres referencias, que responden preguntas distintas:

Referencia	Pregunta que responde
Su categoría	¿Destaca entre sus competidores directos?
Su industria	¿Destaca dentro de su rubro?
Todo el estudio	¿Destaca frente al mercado completo?

Las tres **excluyen a la propia marca**. Compararla contra un promedio que la incluye achica artificialmente la distancia, porque la marca estaría midiéndose en parte contra sí misma.

Detalle del error de la diferencia. La marca y su referencia se estiman con las mismas personas, así que sus errores están relacionados. Se resta la influencia del promedio referente antes de elevar al cuadrado:

$$\widehat{\text{Var}}(\hat{p}_b - \bar{p}_{-b}) = \frac{n}{n-1} \sum_i \left(u_{ib} - \frac{1}{|G|} \sum_{j \in G} u_{ij} \right)^2,$$

donde G son las marcas del grupo de referencia distintas de b y con base suficiente.

Multiplicidad. Las pruebas son bilaterales. Benjamini–Hochberg controla la tasa de falsos descubrimientos al 5 % **por separado en cada referencia**: son tres familias de comparaciones, no una. Un resultado no concluyente no demuestra equivalencia. Los intervalos mostrados son marginales, no simultáneos.

Cuándo falta una referencia. Una categoría con menos de cuatro marcas comparables no produce un promedio publicable: permitiría deducir valores individuales. En ese caso la comparación de categoría aparece vacía y el dashboard cae a la industria, indicándolo explícitamente.

Tabla 17: Cuántas marcas aportan a cada referencia (total del estudio)

Con referencia de categoría	Mediana de marcas en la categoría	Con referencia de industria	Mediana de marcas en la industria	Con referencia del estudio
109	5	109	26	109

El archivo `inferencia_puntajes.csv` contiene límites, errores, referentes, brechas y valores ajustados para las tres referencias. Los dashboards utilizan esas mismas columnas; no replican fórmulas.

4.5. El mapa de cercanía y tecnología

Qué muestra el informe. Cada marca del ranking situada según sus dos puntajes, con las medianas marcadas.

Cómo leerlo. Los ejes son proporciones de asociación, no desempeño financiero ni participación de mercado. Las líneas son medianas de las marcas del ranking de esa edición: se mueven de un año a otro y no son un estándar externo.

Límite. La posición de una marca en el mapa hereda la incertidumbre de sus dos puntajes. Dos marcas visualmente cercanas son, en general, indistinguibles.

5. El recorrido de la marca y sus conversiones

Este capítulo documenta los análisis que hasta ahora solo existían en los *deep dives* preparados a mano para una marca. Ahora se calculan para todas las marcas a la vez y viven en el dashboard.

5.1. Las tres etapas

Qué muestra el producto. Para cada marca de una categoría: cuántos la conocen, cuántos la usan habitualmente y cuántos además la ponen en primer lugar.

Cómo se calcula. Para la marca j y un público G , las tres cantidades se miden sobre el **mismo denominador** —las personas de G asignadas a la industria de j , que son las únicas a quienes se les preguntó por ella— de modo que sean comparables entre sí:

$$\text{conoce}_j = \frac{|\{i \in G_j : \text{conoce } j\}|}{N_{G_j}}, \quad \text{usa}_j = \frac{|\{i \in G_j : \text{compra } j\}|}{N_{G_j}}, \quad \text{usa y prefiere}_j = \frac{|\{i \in G_j : \text{compra } j \wedge j \text{ es su } 1^{\text{a}}\}|}{N_{G_j}}$$

La tercera etapa es una **intersección**, no la preferencia sola: la persona declara comprarla habitualmente *y* ponerla primera. Es la etapa más exigente y la que usan los deep dives.

Cada persona se cuenta una sola vez por etapa y marca. No se impone que quien compra también conozca ni que quien prefiere también compre: las tres se cuentan tal como fueron declaradas.

Tabla 18: Recorrido en el público total, marcas con mayor conocimiento

Marca	Conoce %	Compra %	Prefiere %	Base expuesta
Banco Estado	98.1	58.3	24.6	389
Jumbo	97.1	39.2	11.0	388
Lider	96.2	66.3	13.7	388
Sodimac	95.2	31.2	4.7	388
Falabella	95.2	34.7	10.7	388
Paris	94.8	22.5	9.3	388
Entel	94.6	30.0	10.9	394
Dr. Simi	94.6	41.2	7.4	388
Santa Isabel	93.7	33.2	4.5	388
Cruz verde	93.5	33.4	2.3	388
Copec	93.1	44.9	13.2	394
Correos de Chile	93.0	16.9	3.9	394

Comparación con la edición anterior. Se hace por **nombre de marca**, que es lo único estable: los códigos los reasigna el proveedor cada año. Una marca que entra o sale del listado aparece sin variación, no con variación cero.

5.2. Las funciones de conversión

El problema que resuelven. Una marca poco conocida convierte peor que una muy conocida, y eso no habla de su gestión sino de su tamaño. La tasa cruda —habituales sobre conocedores— tampoco sirve para comparar: con bases chicas salta de un año a otro sin que pase nada real.

Cómo se calcula. Se estima la curva que relaciona una etapa con la siguiente **en todo el mercado**, y se mide a cada marca por su distancia **vertical** a esa curva. Para la conversión de conocimiento a uso habitual:

$$\text{usan}_j \sim \text{Binomial}(\text{conocen}_j, \pi_j), \quad \text{logit}(\pi_j) = \beta_0 + \beta_1 c_j + \beta_2 c_j^2,$$

donde c_j es el porcentaje de conocimiento de la marca. El diferencial publicado es

$$D_j = 100 \left(\frac{\text{usan}_j}{\text{conocen}_j} - \hat{\pi}_j \right)$$

en puntos porcentuales. La segunda curva es análoga, con habitualidad como predictor y «usa y prefiere» como desenlace.

Por qué así y no de otra forma.

- *Modelo binomial sobre el número de personas, no regresión sobre el porcentaje.* Así cada marca pesa según su base y las marcas de nicho no arrastran la curva.
- *Familia quasibinomial.* El número de personas ya ordena el peso, pero la dispersión entre marcas es mayor que la binomial pura —marcas del mismo tamaño convierten distinto por razones de categoría—. Estimar el parámetro de dispersión evita intervalos demasiado angostos.
- *Término cuadrático.* La conversión se acelera a medida que la marca es más conocida; un término lineal en la escala logit no captura esa curvatura.

Dos criterios de lectura, no uno. El deep dive consideraba ventaja estar cinco puntos sobre la curva. Se conserva ese umbral operativo y se agrega el criterio estadístico: si el valor observado cae fuera de la banda de confianza de la propia curva. Un diferencial grande dentro de la banda es una curva mal estimada en ese tramo, no una ventaja de la marca.

Tabla 19: Marcas con mayor ventaja de conversión, de conocer a usar

Marca	Categoría	Observado %	Esperado %	Diferencial	Fuera de la banda
Lider	Supermercados	68.5	34.8	33.8	Sí
Banco Estado	Bancos	60.3	38.6	21.7	Sí
Red Salud	Prestadores	28.5	12.4	16.1	Sí
Compraqui	Servicios de pago	24.8	9.5	15.3	Sí
Blue Express	Distribución y logística	22.2	9.1	13.1	Sí
Dr. Simi	Farmacias	44.3	31.9	12.3	Sí
Integramedica	Prestadores	19.9	7.6	12.3	Sí
Abastible	Servicios básicos	32.5	20.4	12.1	Sí
Aguas	Servicios básicos	19.8	7.7	12.1	Sí
Andinas					
Transbank	Servicios de pago	36.3	24.9	11.4	Sí
Ali Express	Marketplace	25.6	15.3	10.4	Sí
Mercado Libre	Marketplace	36.6	27.1	9.5	Sí

Tabla 20: Resumen de las dos curvas

Etapas	Marcas	Diferencial mediano	Con ventaja (5 puntos)	Fuera de la banda
De conocer a usar	113	-1.6	27	90
De usar a preferir	111	-2.3	36	90

Límites.

- La curva se estima sobre **todo el mercado**, así que las diferencias sistemáticas de categoría aparecen como diferencial. Una empresa de electricidad convierte mucho más que lo que su nivel de conocimiento predice, y eso es una propiedad de la categoría, no de su gestión. La lectura correcta compara dentro de la categoría.
- La conversión es **declarativa**: «compro habitualmente» no es una medida de participación de mercado ni de frecuencia real.

- Ambas etapas provienen de la misma entrevista. El diferencial describe consistencia entre declaraciones, no una secuencia temporal.

6. Qué pesa en la elección

6.1. Importancia declarada e importancia derivada

La distinción. La importancia **declarada** sale de preguntar. La **derivada** sale de modelar qué atributos distinguen a las marcas que la persona efectivamente elige. Las dos miden algo real y no tienen por qué coincidir: un atributo puede mover la elección sin que nadie lo mencione, y viceversa.

Cómo se calcula la derivada. Se construye el menú con las marcas que la persona **evaluó** (Sección 2.2). En la etapa uno se compara la primera preferida contra todo el menú; en la etapa dos se retira la primera, y en la tercera las dos anteriores. Solo se usan etapas con una elegida válida y al menos dos alternativas.

$$P(Y_{is} = b \mid C_{is}) = \frac{\exp(X'_{ib}\beta)}{\sum_{j \in C_{is}} \exp(X'_{ij}\beta)}.$$

Se estima con logit condicional, un estrato por etapa y errores robustos agrupados por persona (`survival::clogit`, método de Efron). Con una sola elegida por estrato la contribución de verosimilitud coincide con la exacta y admite varianza robusta.

Por qué el menú son las evaluadas y no las conocidas. A las marcas conocidas pero no mostradas nunca se les preguntó por atributos: entrarían al modelo con 25 ceros que la persona jamás declaró. Y como el sorteo prioriza a las marcas menos conocidas, esos ceros falsos caerían sobre las marcas grandes —justo las que más compiten por la preferencia—, sesgando los coeficientes hacia cero de manera desigual.

Lo que cuesta. Se pierden las personas cuya marca preferida no les tocó evaluar. La comparación de esas personas no entra al modelo. Es una pérdida de eficiencia conocida y documentada, preferible a una fila inventada.

Tabla 21: Importancia declarada frente a derivada

Atributo	Bloque	Declarada	Derivada	Puesto decl.	Puesto deriv.	Salto	Respalado
Sus transacciones son seguras	EmpatIA	92.0	100.0	1	1	0	Sí
Su sitio web y/o aplicación son de uso fá...	Tecnología	85.6	85.7	7	2	5	Sí
Tiene presencia en todo Chile	EmpatIA	81.2	77.6	12	3	9	Sí
Usa mi mismo lenguaje	Humanidad	79.1	69.5	14	4	10	Sí
Su atención y/o servicio es ágil	Tecnología	86.0	69.2	6	5	1	Sí
Es amable en el trato	Humanidad	85.4	56.8	8	6	2	Sí
Sus procesos son automatizados	Tecnología	73.4	52.6	21	7	14	Sí
Me permite contactarla a través de person...	Humanidad	81.1	52.4	13	8	5	Sí
Me ofrece servicios, productos y/o benefi...	EmpatIA	78.3	43.8	17	9	8	No
Se mantiene actualizada y a la vanguardia ...	Tecnología	78.4	41.3	16	10	6	No
Toma en cuenta y se adapta a las contingencias...	Humanidad	83.1	39.8	11	11	0	No
Innova constantemente en sus productos y/...	Tecnología	76.4	37.8	19	12	7	No

Atributo	Bloque	Decla- rada	Deriva- da	Puesto decl.	Puesto deriv.	Sal- to	Respal- dado
Me hace sentir comprendido	Humani- dad	78.1	37.0	18	13	5	No
Es honesta y transparente	Humani- dad	88.3	34.3	4	14	-10	No
Me regalonea y se preocupa de los detalles	Humani- dad	72.7	29.5	22	15	7	No
Tiene un diseño moderno	Tecnolo- gia	68.9	29.1	23	16	7	No
Se hace cargo de sus errores	Empa- tIA	89.2	28.1	2	17	-15	No
Se preocupa genuinamente de mi	Humani- dad	78.5	24.9	15	18	-3	No
Comparte mis valores y principios	Humani- dad	73.9	24.4	20	19	1	No
Es fácil de contactar	Empa- tIA	86.9	16.6	5	20	-15	No
Soluciona de manera efectiva mis problemas	Empa- tIA	88.6	12.2	3	21	-18	No
Reconoce la antigüedad de nuestra relació...	Humani- dad	84.0	9.6	10	22	-12	No
Se pone en mi lugar cuando tengo un problema	Humani- dad	84.2	0.0	9	23	-14	No

Cómo leer el salto. Positivo significa que la gente lo **subestima** al declararlo: pesa más en la elección de lo que dice. Negativo, que lo sobrevalora al declararlo.

6.2. Ganancia de usar el ranking completo

La encuesta no pide solo la marca favorita: pide primera, segunda y tercera. Usar solo la primera descarta dos tercios de la información. El *logit de ranking explotado* trata la elección ordenada como tres elecciones encadenadas, cada una con su propio estrato.

Tabla 22: Reducción del error al usar el ranking completo en vez de solo la favorita

Atributo	Error solo favorita	Error ranking	Reducción %
Tiene un diseño moderno	0.1417	0.0911	3572
Es tecnológica	0.1370	0.0896	3460
Es fácil de contactar	0.1537	0.1019	3366
Sus transacciones son seguras	0.1440	0.0962	3314
Su atención y/o servicio es ágil	0.1439	0.0966	3284
Me permite contactarla a través de person...	0.1461	0.0985	3258
Sus procesos son automatizados	0.1433	0.0976	3192
Tiene presencia en todo Chile	0.1280	0.0873	3182
Es cercana	0.1355	0.0924	3181
Innova constantemente en sus productos y/...	0.1443	0.0991	3134
Se mantiene actualizada y a la vanguardia ...	0.1403	0.0965	3122
Soluciona de manera efectiva mis problemas	0.1567	0.1094	3016

6.3. Por industria y por desenlace

Qué agrega. Los deep dives estimaban esto con un análisis discriminante sobre personas. Aquí se usa el mismo modelo condicional del resto del proyecto, por dos razones: compara a la persona consigo misma —quien marca muchos atributos en todas las marcas no infla el resultado— y respeta el diseño, porque cada persona ve un menú distinto y el modelo condiciona en ese menú.

Se estima dos veces, con dos desenlaces:

Desenlace	Variable	Estrato	Observación
Preferencia	Primera, segunda o tercera preferida	Persona $\times$ etapa	Una marca por estrato
Habitualidad	Compra habitualmente (P11)	Persona	Puede marcar varias

Para habitualidad el modelo es un **logit de efectos fijos por persona**: la misma verosimilitud condicional, ahora con varios positivos por estrato. Se exige variación dentro de la persona —si usa todas las marcas que evaluó, o ninguna, no aporta comparación—.

Y por separado dentro de cada industria, porque lo que hace que alguien prefiera un banco no tiene por qué ser lo que lo hace preferir un supermercado. Un ámbito con menos de 40 comparaciones no se estima: veinticinco atributos no se sostienen con esa base.

Tabla 23: Los cinco atributos de mayor peso en cada ámbito, para la preferencia

Ámbito	Atributo	Peso	Índice	Respalda- do	Comparacio- nes
Aseguradoras	Usa mi mismo lenguaje	0.63	100	Sí	653
Aseguradoras	Tiene presencia en todo Chile	0.50	88	Sí	653
Aseguradoras	Sus transacciones son seguras	0.50	88	Sí	653
Aseguradoras	Su sitio web y/o aplicación son de us...	0.46	85	No	653
Aseguradoras	Me permite contactarla a través de pe...	0.43	82	No	653
Retail	Es cercana	0.72	100	Sí	582
Retail	Sus transacciones son seguras	0.63	91	Sí	582
Retail	Usa mi mismo lenguaje	0.60	88	Sí	582
Retail	Es amable en el trato	0.55	82	Sí	582
Retail	Tiene presencia en todo Chile	0.50	77	Sí	582
Servicios esenciales	Sus transacciones son seguras	0.86	100	Sí	622
Servicios esenciales	Su sitio web y/o aplicación son de us...	0.58	80	Sí	622
Servicios esenciales	Tiene presencia en todo Chile	0.54	77	Sí	622
Servicios esenciales	Es tecnológica	0.53	76	Sí	622
Servicios esenciales	Se preocupa genuinamente de mi	0.51	75	No	622
Servicios financieros	Sus transacciones son seguras	0.95	100	Sí	707
Servicios financieros	Su sitio web y/o aplicación son de us...	0.82	90	Sí	707
Servicios financieros	Sus procesos son automatizados	0.55	70	Sí	707
Servicios financieros	Me ofrece servicios, productos y/o be...	0.55	70	No	707
Servicios financieros	Es cercana	0.52	68	Sí	707
Total	Sus transacciones son seguras	0.73	100	Sí	2564
Total	Su sitio web y/o aplicación son de us...	0.60	86	Sí	2564
Total	Tiene presencia en todo Chile	0.53	78	Sí	2564
Total	Es cercana	0.50	74	Sí	2564
Total	Usa mi mismo lenguaje	0.45	70	Sí	2564

Tabla 24: Los cinco atributos de mayor peso en cada ámbito, para la habitualidad

Ámbito	Atributo	Peso	Índice	Respalda- do	Comparacio- nes
Aseguradoras	Su sitio web y/o aplicación son de us...	0.75	100	Sí	229
Aseguradoras	Me permite contactarla a través de pe...	0.60	88	Sí	229
Aseguradoras	Toma en cuenta y se adapta a las cont...	0.59	87	Sí	229
Aseguradoras	Sus transacciones son seguras	0.56	84	Sí	229
Aseguradoras	Usa mi mismo lenguaje	0.47	78	No	229
Retail	Es cercana	0.78	100	Sí	245
Retail	Sus transacciones son seguras	0.73	95	Sí	245
Retail	Tiene presencia en todo Chile	0.59	81	Sí	245
Retail	Es amable en el trato	0.34	57	Sí	245
Retail	Toma en cuenta y se adapta a las cont...	0.32	55	Sí	245
Servicios esenciales	Sus transacciones son seguras	0.67	100	Sí	245
Servicios esenciales	Su sitio web y/o aplicación son de us...	0.56	90	Sí	245
Servicios esenciales	Tiene presencia en todo Chile	0.53	86	Sí	245
Servicios esenciales	Su atención y/o servicio es ágil	0.41	75	Sí	245
Servicios esenciales	Me hace sentir comprendido	0.40	74	No	245
Servicios financieros	Sus transacciones son seguras	0.98	100	Sí	260
Servicios financieros	Su sitio web y/o aplicación son de us...	0.86	92	Sí	260
Servicios financieros	Sus procesos son automatizados	0.63	77	Sí	260
Servicios financieros	Tiene presencia en todo Chile	0.55	72	Sí	260
Servicios financieros	Es cercana	0.55	72	Sí	260
Total	Sus transacciones son seguras	0.73	100	Sí	979
Total	Es cercana	0.55	81	Sí	979
Total	Tiene presencia en todo Chile	0.55	80	Sí	979
Total	Su sitio web y/o aplicación son de us...	0.50	75	Sí	979
Total	Toma en cuenta y se adapta a las cont...	0.33	56	Sí	979

Límites.

- Comparar coeficientes entre logits separados depende también de su escala residual. Un coeficiente mayor en una industria no prueba que el atributo «importe más» ahí; prueba que separa más dentro de ese menú. Por eso se publica además el índice 0–100 dentro de cada modelo, que es lo comparable.
- Un orden distinto entre industrias **no prueba una interacción**. Para afirmarla haría falta un modelo con términos de interacción y su propia prueba.
- La habitualidad y los atributos se declaran en la misma entrevista. La asociación no separa «lo uso porque es ágil» de «me parece ágil porque lo uso».

6.4. Cuánto pesa cada bloque

Tabla 25: Peso relativo de los bloques de atributos en la elección

dimension	peso	error	p	peso_relativo	ic_bajo	ic_alto
Tecnologia	1.879	0.164	0	0.340	1.557	2.201
Humanidad	1.857	0.289	0	0.336	1.290	2.424
EmpatIA	1.793	0.217	0	0.324	1.367	2.219

Ver la advertencia de la Sección 4: estos coeficientes corresponden a pasar de cero a todos los atributos del bloque y **no** son ponderadores equivalentes a los del índice.

7. Fortalezas y debilidades

7.1. La matriz de importancia y perfilamiento

Qué muestra el producto. Cada atributo situado según cuánto le importa al mercado (eje horizontal) y cuánto destaca la marca en él frente a su categoría (eje vertical).

Cómo se construye.

- *Eje horizontal:* el índice de importancia declarada de la Sección 3.
- *Eje vertical:* $100(\hat{p}_{ba} - \bar{p}_{-b,a})$, donde $\bar{p}_{-b,a}$ es el promedio de las **otras** marcas de su categoría con base suficiente. Cuando la categoría no alcanza el mínimo de marcas, se usa la industria y la tabla lo registra en una columna.
- *Corte horizontal:* cero, es decir el promedio de la referencia.
- *Corte vertical:* la mediana de importancia de los atributos.

De ahí los cuatro nombres, y cada uno pide una decisión distinta:

Cuadrante	Importa	Destaca	Qué hacer
Fortalezas	Sí	Sí	Sostener y comunicar
Debilidades	Sí	No	La brecha a trabajar
Recursos	No	Sí	Activo disponible si el mercado se mueve
Latentes	No	No	Reserva, no prioridad

El criterio estadístico. La tabla marca aparte si la distancia supera su propio margen, con el mismo procedimiento de la Sección 4.4 —error de la diferencia con la referencia excluida y ajuste de Benjamini-Hochberg—. Una fortaleza dentro del margen es un empate, no una ventaja, y no debería sostener una decisión.

Tabla 26: Reparto de los atributos entre cuadrantes, para las marcas del top 5

Marca	Fortalezas	Recursos	Sin importancia declarada	Latentes
Entel	12	11	2	0
Falabella	12	11	2	0
Lider	12	11	2	0
Mercado Libre	12	11	2	0
Mercado Pago	12	10	2	1

Tabla 27: Cuántas fortalezas superan el margen de la encuesta

Pares marca-atributo	En Fortalezas	Fortalezas respaldadas	En Debilidades	Debilidades respaldadas
2725	571	177	737	233

La brecha entre «en Fortalezas» y «Fortalezas respaldadas» es la medida honesta de cuánto de esta lámina se puede afirmar. La mayoría de los pares cae dentro del margen: con bases cercanas a doscientas personas y veinticinco comparaciones por marca, eso es lo esperable.

Límites.

- El eje horizontal es importancia **declarada**. Usar la derivada (Sección 6.3) cambia el reparto de cuadrantes; las dos lecturas están disponibles y no tienen por qué coincidir.
- El corte de importancia es la mediana: una convención, no un umbral con contenido. Un atributo apenas sobre la mediana y otro apenas bajo ella no son categorías distintas.

7.2. Perfilamiento dentro de la categoría

El problema. Si se comparan los puntajes tal cual, una marca grande aparece destacando en todos los atributos a la vez. Eso es tamaño, no perfil.

La corrección. Para la marca b y el atributo a dentro de la categoría c :

$$A_{ba} = 100 [\hat{p}_{ba} - (\bar{p}_{b.} + \bar{p}_{.a} - \bar{p}_{..})]$$

donde $\bar{p}_{b.}$ es el nivel general de la marca dentro de la categoría, $\bar{p}_{.a}$ lo que la categoría entera asocia a ese atributo, y $\bar{p}_{..}$ el nivel general de la categoría. Lo sustraído es lo esperable si la marca no tuviera perfil propio; lo que queda es su apropiación.

Es la misma lógica de un análisis de correspondencias: el residuo respecto de lo que predicen la fila y la columna. Se calcula sobre una tabla de proporciones y no de frecuencias, así que no es un χ^2 y no lleva su prueba asociada.

Tabla 28: Mayor apropiación por categoría (primeras categorías del listado)

Categoría	Marca	Atributo	Apropia- ción	Importan- cia
Bancos	Banco Estado	Tiene presencia en todo Chile	24.2	81
Tiendas de conveniencia	Pronto	Tiene presencia en todo Chile	22.3	81
Mejoramiento del hogar	Sodimac	Tiene presencia en todo Chile	18.6	81
Distribución y logística	Blue Express	Tiene un diseño moderno	16.5	69
Farmacias	Dr. Simi	Es cercana	15.1	NA
Marketplace	Ripley	Me permite contactarla a través de ...	13.9	81
Distribución y logística	Correos de Chile	Tiene presencia en todo Chile	13.6	81
Mejoramiento del hogar	Ikea	Tiene un diseño moderno	13.6	69
Seguros	ACHS	Tiene presencia en todo Chile	13.2	81
Servicios de pago	Caja Vecina	Es cercana	13.2	NA
Servicios de pago	Getnet	Es tecnológica	13.1	NA
Marketplace	Falabella	Tiene presencia en todo Chile	12.7	81

Límites. Una categoría con dos marcas produce apropiaciones simétricas por construcción: lo que una tiene de más, la otra lo tiene de menos. La lectura es informativa desde tres marcas. Las categorías con una sola marca comparable quedan fuera de la tabla.

8. ¿Y si el índice usara todos los atributos?

El índice publicado combina dos atributos. El estudio mide veinticinco. Este capítulo documenta qué pasaría si se resumiera la marca de otra forma, y por qué la edición mantiene la fórmula vigente. Es la sección más extensa del apéndice porque es la decisión más consecuente del estudio.

8.1. Unidad de análisis

La unidad es el par persona-marca. Una persona i a quien el cuestionario **mostró** la marca j en la batería de atributos (Sección 2.2) responde 25 preguntas binarias: $y_{ijk} = 1$ si le asocia el atributo k , y 0 si no. Las marcas que conoce pero que no le fueron mostradas no entran: sus veinticinco ceros no son respuestas.

Las evaluaciones de una misma persona están correlacionadas, porque quien marca un atributo tiende a marcar varios. Para la estimación del modelo de medición esto no invalida los parámetros, pero sí implica que el tamaño efectivo de muestra es menor que el número de filas. Por eso las comparaciones entre índices se validan por división de personas y no por división de filas.

8.2. Dimensionalidad

Con respuestas binarias, la correlación de Pearson subestima la asociación entre ítems. Se utiliza la **correlación tetracórica** ρ_{kl}^* , que estima la correlación de dos variables continuas latentes y_k^*, y_l^* cuya dicotomización produce las respuestas observadas:

$$y_{ijk} = \mathbb{1} [y_{ijk}^* > \tau_k], \quad \begin{pmatrix} y_k^* \\ y_l^* \end{pmatrix} \sim N \left(0, \begin{pmatrix} 1 & \rho_{kl}^* \\ \rho_{kl}^* & 1 \end{pmatrix} \right)$$

donde τ_k es el umbral del ítem k .

Sobre esa matriz se aplica **análisis paralelo de Horn**: se compara el valor propio de cada dimensión contra la distribución de valores propios en datos sin estructura, generados con las mismas dimensiones y tamaño muestral.

Con muestras grandes el análisis paralelo tiende a señalar dimensiones de magnitud despreciable, porque casi cualquier valor propio supera al de datos aleatorios. Por eso el criterio de decisión no es únicamente cuántas dimensiones “pasan”, sino la **magnitud relativa** de la primera frente a las siguientes.

Tabla 29: Magnitud de cada dimensión

Dimensión	Cuánto explica
1	16.264
2	0.682
3	0.379
4	0.122
5	0.086
6	0.081
7	0.035
8	0.013

8.3. Proporción atribuible a una dimensión general

Se estima un modelo con un factor general y factores de grupo. Dos cantidades resumen el resultado:

$$\omega_h = \frac{(\sum_k \lambda_{gk})^2}{\text{Var}(X_t)}, \quad \text{ECV} = \frac{\sum_k \lambda_{gk}^2}{\sum_k \lambda_{gk}^2 + \sum_k \sum_f \lambda_{fk}^2}$$

donde λ_{gk} es la carga del ítem k en el factor general, λ_{fk} su carga en el factor de grupo f , y $\text{Var}(X_t)$ la varianza de la suma de los ítems. ω_h es la proporción de la varianza de la puntuación total atribuible al factor general; ECV es la proporción de la varianza común explicada por ese factor.

Tabla 30: Resumen de la estructura

indicador	valor
Evaluaciones persona-marca	20903.000
Correlacion tipica entre atributos	0.648
Importancia de la primera dimension	16.260
Importancia de la segunda dimension	0.680
Varianza comun explicada por una sola dimension	65.000
Proporcion atribuible a la dimension general	0.887
Confiabilidad del conjunto de 25	0.982

8.4. Discriminación de los ítems

Se ajusta un modelo logístico de dos parámetros. La probabilidad de que la evaluación con nivel latente θ endose el atributo k es:

$$P(y_k = 1 \mid \theta) = \frac{1}{1 + \exp[-a_k(\theta - b_k)]}$$

a_k es la **discriminación**: cuánto separa el ítem entre evaluaciones de nivel alto y bajo. b_k es la **dificultad**: el nivel θ en que la probabilidad de endoso alcanza 0,5. Un a_k alto indica un atributo informativo; un a_k bajo, uno que marca casi cualquiera.

Tabla 31: Discriminación y dificultad por atributo

Atributo	Bloque	Discriminación	Dificultad
Me hace sentir comprendido	Humanidad	3.53	1.45
Soluciono de manera efectiva mis problemas	EmpatIA	3.49	1.34
Se pone en mi lugar cuando tengo un problema	Humanidad	3.33	1.62
Su atención y/o servicio es ágil	Tecnología	3.25	1.12
Se preocupa genuinamente de mi	Humanidad	3.21	1.60
Comparte mis valores y principios	Humanidad	3.05	1.53
Reconoce la antigüedad de nuestra relación ...	Humanidad	3.03	1.53
Es honesta y transparente	Humanidad	2.96	1.32
Se hace cargo de sus errores	EmpatIA	2.91	1.48
Me ofrece servicios, productos y/o benefici...	EmpatIA	2.79	1.35
Es cercana	Humanidad	2.78	1.31
Me regalona y se preocupa de los detalles	Humanidad	2.76	1.72
Es amable en el trato	Humanidad	2.75	1.11
Es fácil de contactar	EmpatIA	2.73	1.20
Su sitio web y/o aplicación son de uso fáci...	Tecnología	2.70	1.02
Se mantiene actualizada y a la vanguardia te...	Tecnología	2.52	1.04
Innova constantemente en sus productos y/o ...	Tecnología	2.51	1.20
Sus transacciones son seguras	EmpatIA	2.44	0.82
Tiene un diseño moderno	Tecnología	2.08	1.28
Toma en cuenta y se adapta a las contingenc...	Humanidad	2.01	1.01
Sus procesos son automatizados	Tecnología	2.00	1.04
Es tecnológica	Tecnología	2.00	0.95
Usa mi mismo lenguaje	Humanidad	1.97	0.96

Atributo	Bloque	Discriminación	Dificultad
Me permite contactarla a través de personas...	Humanidad	1.88	1.24
Tiene presencia en todo Chile	EmpatIA	1.35	0.49

8.5. Índices comparados

Para la marca j se define p_{jk} como la proporción de quienes la conocen que le asocian el atributo k . Los cuatro índices son:

$$\begin{aligned}
I_j^{\text{pub}} &= w_c p_{j,\text{cercana}} + w_t p_{j,\text{tecnologica}} \\
I_j^{\text{prom}} &= \frac{1}{25} \sum_k p_{jk} \\
I_j^{\text{pond}} &= \sum_k \beta_k p_{jk} \\
I_j^{\text{modelo}} &= \frac{1}{n_j} \sum_{i \in C_j} \hat{\theta}_{ij}
\end{aligned}$$

donde w_c, w_t son los ponderadores publicados del año; β_k el coeficiente del atributo k en el modelo de preferencias; C_j el conjunto de personas que evaluaron la marca j ; $n_j = |C_j|$; y $\hat{\theta}_{ij}$ la puntuación esperada a posteriori del modelo de ítems.

8.6. Criterio de comparación

El criterio externo es la preferencia declarada, que ningún índice utiliza en su construcción. Se reporta con dos denominadores, porque definen preguntas distintas:

$$\text{share}_j = 100 \cdot \frac{m_j}{N}, \quad \text{tasa}_j = 100 \cdot \frac{m_j}{n_j}$$

con m_j el número de personas que ponen a la marca j en primer lugar y N el total de la muestra. El *share* mezcla calidad de percepción con notoriedad; la *tasa* aísla la percepción del tamaño de la marca. La comparación principal usa la tasa.

La asociación se mide con correlación de Spearman, apropiada porque el interés es el ordenamiento de marcas y no la escala.

8.7. Estabilidad

Se divide la muestra de personas en dos mitades al azar, se calculan los cuatro índices en cada una y se correlaciona el orden resultante. Se repite 15 veces y se reporta la mediana. Un índice estable produce un orden similar con personas distintas.

Tabla 32: Comparación completa de los cuatro índices

Índice	Con share	Con tasa	Estabilidad
Promedio de todos los atributos	0.732	0.690	0.845
Índice publicado (2 atributos)	0.686	0.663	0.820
Todos los atributos ponderados por la elección	0.715	0.641	0.860
Puntuación del modelo de ítems	0.690	0.630	0.883

8.8. Alternativa evaluada y descartada

El promedio de puntuaciones $\hat{\theta}$ obtiene la peor asociación con el criterio, pese a provenir del modelo de medición mejor especificado. La razón es de agregación, no de ajuste.

La puntuación esperada a posteriori es un estimador contraído hacia la media poblacional:

$$\hat{\theta}_{ij} = E[\theta | \mathbf{y}_{ij}] \approx \frac{\sigma_{\theta}^2}{\sigma_{\theta}^2 + \sigma_e^2(\mathbf{y}_{ij})} \tilde{\theta}_{ij}$$

donde $\tilde{\theta}_{ij}$ es la estimación no contraída y σ_e^2 el error de medición de esa evaluación. La contracción es apropiada para ordenar evaluaciones individuales, pero al promediar dentro de una marca reduce sistemáticamente la varianza entre marcas, que es exactamente la señal de interés.

Este resultado se documenta porque el descarte de una alternativa con evidencia es parte del análisis: no se adoptó un método más sofisticado por serlo, sino que se comprobó que no resolvía mejor el problema.

8.9. Consecuencia sobre el ranking

Tabla 33: Marcas con mayor cambio de puesto

Marca	Industria	Base	Puesto publicado	Puesto con todos	Cambio
Transbank	Servicios financieros	342	44	80	-36
Abastible	Servicios esenciales	326	79	48	31
Caja Vecina	Servicios financieros	352	32	60	-28
Compraqui	Servicios financieros	121	47	75	-28
Starken	Servicios esenciales	322	81	55	26
Salcobrand	Retail	349	68	42	26
Chek	Servicios financieros	104	60	86	-26
Easy	Retail	352	50	25	25
Farmacias	Retail	343	97	74	23
Ahumada					
Cencopay	Servicios financieros	150	35	58	-23
Santa Isabel	Retail	363	46	24	22
Getnet	Servicios financieros	119	16	38	-22
Sky Airline	Servicios esenciales	262	89	68	21
Tenpo	Servicios financieros	240	12	32	-20
Tapp	Servicios financieros	120	43	63	-20

8.10. Comportamiento de los ítems entre públicos

Si un atributo discrimina en un público y no en otro, comparar puntajes entre públicos deja de ser directo. Se estima el modelo por separado en cada público con al menos 200 personas y se comparan las discriminaciones resultantes mediante correlación de Spearman.

Tabla 34: Concordancia de las discriminaciones entre públicos

Públicos comparados	Concordancia mínima	Concordancia media
8	0.844	0.926

Esta es una comprobación de orden, no una prueba formal de invariancia de medición. Una concordancia alta indica que los atributos ordenan de forma similar en todos los públicos; no descarta diferencias en los umbrales de cada ítem.

8.11. Limitaciones de esta sección

- El criterio de validación es una preferencia declarada dentro de la misma encuesta, no una conducta observada.
- La alta correlación entre atributos implica que la comparación entre índices tiene menos poder del que sugiere el número de marcas: todos comparten gran parte de su información.
- La adopción de un índice no es una decisión estadística. Requiere definir primero qué debe medir el índice; la evidencia aquí presentada informa esa decisión pero no la reemplaza.

9. Resultados por público

9.1. Construcción

El ranking completo se recalcula **dentro de cada público**: los puntajes, el índice y el puesto se estiman usando solo a las personas de ese grupo. No se reordena el ranking general.

Los públicos provienen de tres clasificaciones —género, generación, grupo socioeconómico— que **no son excluyentes entre sí**: una misma persona pertenece a un nivel de cada una. Las cifras de distintas clasificaciones no se suman.

Una marca entra al ranking de un público solo si al menos 60 personas de ese público la conocen. Bajo ese umbral el puntaje tiene un margen tan amplio que el puesto deja de ser informativo.

Tabla 35: Cobertura del ranking por público

Clasificación	Público	Marcas con puesto	Conocimiento mediano
GSE	ABC1	113	73
GSE	C2	113	58
GSE	C3	113	83
GSE	D/E	113	49
Generacion	45 o mas	113	136
Generacion	Menores de 45	113	145
Genero	Hombres	113	142
Genero	Mujeres	113	138
Total	Total	113	279

10. El mapa de calor por público y su descomposición

10.1. La matriz

Para la marca m se arma una matriz G de 25 atributos por niveles de público, donde cada celda es la diferencia contra el promedio de **las otras** marcas de su industria en ese público:

$$G_{as} = \hat{p}_{as}^{(m)} - \frac{1}{|R_s|} \sum_{r \in R_s} \hat{p}_{as}^{(r)}$$

con R_s el conjunto de marcas del mismo rubro, excluida m , con base suficiente en el público s . Excluir a la propia marca del referente evita que se compare parcialmente contra sí misma, lo que reduciría artificialmente la diferencia.

10.2. Precisión de cada celda

Dentro de un público, el número de personas que conoce una marca cae sustancialmente. El margen de cada celda se aproxima con el error estándar de una proporción:

$$\hat{\sigma}_{as} = \sqrt{\frac{\hat{p}_{as}(1 - \hat{p}_{as})}{n_{as}}}$$

Una celda se considera distinguible del azar cuando $|G_{as}| > 2\hat{\sigma}_{as}$. Las demás se muestran en gris: **no son diferencias pequeñas, son diferencias que la encuesta no permite afirmar**.

Tabla 36: Precisión del mapa por tipo de público

segmento	celdas	distinguibles	proporcion	error_mediano	brecha_mediana
Genero	4375	1296	0.30	3.52	4.89
Generacion	4325	1296	0.30	3.53	5.08
GSE	1025	228	0.23	3.81	4.54

10.3. Separación entre perfil y público

La matriz se descompone en valores singulares:

$$G = \sum_k d_k u_k v'_k$$

El primer término es la mejor aproximación de rango uno en mínimos cuadrados (Eckart y Young, 1936):

$$G_{as} \approx \underbrace{d_1 u_{1a}}_{\text{perfil del atributo}} \times \underbrace{v_{1s}}_{\text{intensidad del público}}$$

Interpretación: la marca tiene un perfil de fortalezas y debilidades, y ese perfil aparece en cada público multiplicado por un factor de intensidad. Si todas las componentes de v_1 comparten signo, la **forma** del perfil no cambia entre públicos, solo su magnitud.

El signo del par (u_1, v_1) es arbitrario: multiplicar ambos por -1 da la misma aproximación. Se fija de modo que la suma de v_1 sea positiva.

Tabla 37: Resultado de la descomposición

marcas	varianza_perfil_mediana	marcas_con_perfil_estable	variacion_mediana
80	0.869	74	0.194

10.4. Estabilidad del espacio entre públicos

Pregunta distinta: no cómo se ve una marca en cada público, sino si la estructura del mercado es la misma para todos. Se reconstruye el espacio de posicionamiento dentro de cada público y se comparan los ejes resultantes, alineando previamente los signos.

Tabla 38: Correlación de los ejes entre públicos

eje	segmentos	correlacion_media	correlacion_minima
Eje 1	5	0.871	0.688
Eje 2	5	0.350	-0.095

10.5. Métodos considerados y descartados

Se evaluaron tres alternativas para leer estas matrices:

- **Agrupamiento jerárquico de filas y columnas.** Reordena la matriz para que atributos y públicos parecidos queden contiguos. Mejora la legibilidad pero no aporta inferencia, y sobre una matriz con esta relación señal-ruido produce bloques visuales convincentes a partir de ruido. Se usa solo como criterio de ordenamiento.
- **Descomposición espectral de la matriz de correlación entre atributos.** Requiere estimar correlaciones dentro de cada público, con menos observaciones aún que las celdas.
- **Descomposición en valores singulares de la matriz de brechas.** La adoptada: opera directamente sobre la cantidad de interés y su primera capa tiene lectura de negocio.

El valor de la descomposición aquí no es descubrir estructura oculta sino **separar la parte estable de la ruidosa**: la primera capa promedia información a través de todas las celdas y es mucho más precisa que cualquier celda individual.

11. Perfiles de personas que las segmentaciones habituales no ven

11.1. Unidad y espacio

Para la persona i que conoce M_i marcas, su perfil es el vector de proporciones

$$x_{ik} = \frac{1}{M_i} \sum_{j \in C_i} y_{ijk}$$

donde $y_{ijk} = 1$ si asocia el atributo k a la marca j . Se exige $M_i \geq 8$.

El primer componente de x recoge la **generosidad al marcar**, no el contenido. Como interesa la forma del perfil, cada persona se centra y escala en su propia distribución:

$$z_{ik} = \frac{x_{ik} - \bar{x}_i}{s_i}$$

El número de direcciones a retener se determina por análisis paralelo contra permutaciones.

11.2. Dos métodos, dos preguntas

HDBSCAN busca regiones densas separadas por zonas vacías, y deja sin grupo a quien no pertenece a ninguna. Una proporción alta de personas sin grupo indica ausencia de tribus separadas, no un fallo del método.

Mezcla gaussiana finita: la densidad se modela como

$$f(z) = \sum_{g=1}^G \pi_g \phi(z \mid \mu_g, \Sigma_g), \quad \sum_g \pi_g = 1$$

con π_g el peso del componente g , μ_g su centro y Σ_g su matriz de covarianza. El criterio BIC selecciona simultáneamente G y la parametrización de Σ_g (esférica, diagonal o completa; de volumen y forma iguales o distintos). Cada persona recibe la probabilidad posterior τ_{ig} de pertenecer a cada componente; se reporta $1 - \max_g \tau_{ig}$ como incertidumbre.

11.3. Estabilidad

Se divide la muestra en mitades, se estima el modelo en cada una y se compara la partición con el **índice de Rand ajustado**:

$$\text{ARI} = \frac{\sum_{ij} \binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}}$$

donde n_{ij} cuenta elementos en el grupo i de una partición y j de la otra, a_i y b_j son sus marginales. Vale 1 si coinciden y alrededor de 0 si el acuerdo es el del azar.

Tabla 39: Selección del número de componentes por BIC

grupos	bic	elegido
1	-14382	FALSE
2	-13845	FALSE
3	-13418	FALSE
4	-13310	TRUE
5	-13582	FALSE

grupos	bic	elegido
6	-13569	FALSE
7	-13593	FALSE
8	-13565	FALSE

Tabla 40: Búsqueda de grupos por densidad (HDBSCAN)

minimo_por_grupo	grupos	sin_grupo
30	2	75.6
60	2	78.7
120	0	100.0
250	0	100.0

acuerdo_medio	acuerdo_minimo	repeticiones	grupos	certeza_media	sin_grupo_densidad
0.329	0.259	10	4	0.88	75.62

grupo	personas	certeza	porcentaje
1	97	0.87	6.86
2	185	0.85	13.07
3	574	0.87	40.57
4	559	0.90	39.51

Estabilidad y tamaño de los perfiles

Tabla 41: Coincidencia con las segmentaciones demográficas

segmentacion	acuerdo	cramer
genero	0.001	0.050
generacion	0.011	0.122
grupo_nse	0.003	0.069

La **V de Cramér** mide asociación entre dos clasificaciones: $V = \sqrt{\chi^2/[n(\min(r, c) - 1)]}$, con r y c el número de categorías. Vale 0 si son independientes y 1 si una determina a la otra.

12. Territorios de marcas

Se aplica la misma mezcla gaussiana al espacio de posicionamiento de las marcas. A diferencia del agrupamiento por particiones, que exige fijar el número de grupos, aquí BIC lo selecciona, y cada marca recibe una probabilidad de pertenencia a cada territorio en vez de una etiqueta rígida.

12.1. Orientación de los ejes

El signo de un componente principal es arbitrario: $(-u_k, -v_k)$ describe el mismo patrón que (u_k, v_k) . Sin fijarlo, un eje puede aparecer invertido entre ediciones y simular un giro del mercado inexistente.

Cada eje se orienta de modo que su carga sobre un **atributo de referencia fijo** sea positiva; si ese atributo tiene carga despreciable ($|\lambda| \leq 0,05$), se usa como respaldo el de mayor carga absoluta. Las referencias son las mismas en todas las ediciones.

Tabla 42: Territorios: número, forma y marcas sin asignación clara

territorios	modelo	certeza_media	marcas_ambiguas
5	VEI	0.932	4

Tabla 43: Probabilidad de pertenencia por marca (primeras filas)

marca	territorio_1	territorio_2	territorio_3	territorio_4	territorio_5
Cruz verde	0.915	0.085	0.000	0.000	0
Farmacias Ahumada	0.984	0.016	0.000	0.000	0
Dr. Simi	0.000	1.000	0.000	0.000	0
Salcobrand	0.984	0.016	0.000	0.000	0
Easy	0.720	0.087	0.193	0.000	0
Sodimac	0.494	0.088	0.394	0.025	0
Casa Ideas	0.000	1.000	0.000	0.000	0
Ikea	0.000	1.000	0.000	0.000	0
Mercado Libre	0.000	0.031	0.969	0.000	0
Falabella	0.000	0.019	0.974	0.007	0
Hites	0.034	0.966	0.000	0.000	0
La Polar	0.981	0.015	0.003	0.000	0

13. Posicionamiento: cómo se construye el mapa

Los perfiles se centran y normalizan por marca para describir su forma. PCA produce un mapa exploratorio; la varianza explicada no constituye validación predictiva. Los signos de sus ejes son arbitrarios y se orientan mediante atributos guía. El análisis paralelo compara espectros con permutaciones; sus supuestos no convierten automáticamente cada eje en una dimensión de negocio.

Se comparan agrupaciones PAM mediante separación interna y una prueba adicional de veinte mitades independientes: acuerdo ajustado de Rand entre particiones de las mismas marcas y silueta en la mitad externa usando los medoides de entrenamiento. Se exploran dos a seis grupos. Los umbrales operativos de acuerdo 0,65 y silueta externa 0,25 describen estabilidad, no una prueba de significación; si ninguno los cumple no se confirma una segmentación.

Se comparan agrupaciones PAM mediante separación interna. UMAP/HDBSCAN son alternativas exploratorias, sensibles a hiperparámetros y semillas. La selección interna de un número de grupos no demuestra estabilidad externa ni segmentos comerciales reales. Las tablas históricas se conservan como diagnóstico, no como resultados confirmatorios.

La descomposición de brechas por segmentos mediante SVD resume el perfil común y la variación residual. Los públicos se solapan y los referentes comparten personas. Por eso la reconstrucción interna no prueba que las «tribus» o componentes se reproduzcan. Las pruebas de diferencias del dashboard provienen de la nueva inferencia conjunta, no del antiguo criterio de dos errores de la marca aislada.

componentes	error_estandar	error	divisiones	recomendado
0	0	0.003	20	FALSE
1	0	0.002	20	FALSE
2	0	0.002	20	FALSE
3	0	0.002	20	FALSE
5	0	0.002	20	TRUE
8	0	0.002	20	FALSE
12	0	0.002	20	FALSE
20	0	0.002	20	FALSE
24	0	0.002	20	FALSE

grupos	acuerdo	silueta_externa	estabilidad_suficiente
2	0.239	0.176	FALSE
3	0.373	0.124	FALSE
4	0.317	0.103	FALSE
5	0.296	0.091	FALSE
6	0.285	0.080	FALSE

14. Del modelo de elección a los escenarios

14.1. Regularización y evaluación fuera de muestra

Predicciones y escenarios usan una penalización ridge sobre la log-verosimilitud media por etapa, $\lambda\|\beta\|^2/2$. Los atributos son binarios y comparten escala. La optimización verifica convergencia y emplea probabilidades con centrado por menú para evitar desbordamientos.

Se usan tres pliegues externos de personas completas. En cada entrenamiento se construyen tres pliegues internos para elegir entre $\lambda \in \{0.001, 0.01, 0.1, 1\}$. La regla de un error estándar prefiere la penalización mayor entre ajustes comparables. Ninguna respuesta de una persona del pliegue externo participa en selección ni ajuste de su modelo.

Los referentes «marca más conocida» e «índice» se vuelven a calcular con las personas del entrenamiento elegibles para la tarea. Una marca ausente del entrenamiento no recibe información del pliegue de prueba. Los empates distribuyen el acierto entre alternativas empatadas. El azar asigna crédito $1/|C_i|$.

Se registra acierto de primera preferencia para todos los criterios y log-loss y Brier multiclase para el modelo probabilístico. Los intervalos de acierto usan 1.000 remuestreos de personas sobre predicciones externas, condicionados a los ajustes; no incluyen toda la variación por volver a elegir pliegues y modelos. El ajuste final selecciona su penalización de nuevo usando todos los datos, exclusivamente para escenarios y descripción posterior.

criterio	acierto	ic_bajo	ic_alto	personas_prueba
Azar	8.65	8.34	9.00	1044
Indice EmpatIA	16.55	14.16	19.34	1044
Marca mas conocida	17.45	14.67	20.26	1044
Modelo de eleccion	48.31	44.69	51.56	1044

perdida	brier
1.676	0.6992

La validación evalúa nuevas personas de la misma edición con percepciones contemporáneas disponibles. No acredita predicción de ventas, nuevas marcas o nuevas olas. Las columnas por persona están en `validacion_personas.csv`; se conservan separadas de la presentación ejecutiva.

14.2. Escenarios de marca y público

El escenario activa un atributo entre una fracción f de quienes evaluaron la marca y todavía no se lo asocian. **No añada f puntos porcentuales a toda la base.** Para una persona con probabilidad p y coeficiente β , la nueva probabilidad es:

$$p' = \frac{e^\beta p}{1 + (e^\beta - 1)p}.$$

Se suma $f(p' - p)$ sobre personas sin asociación y se divide por todas las personas elegibles del público. Se expresa en puntos de primera preferencia. La interfaz recalcula sobre el público elegido usando los pesos poblacionales regularizados compartidos; no estima un modelo causal específico de marca o segmento.

No se asignan intervalos de efecto a un escenario hipotético: la incertidumbre de una intervención real no queda identificada por esta encuesta. Los escenarios son análisis de sensibilidad del modelo, no estimaciones confirmatorias de retorno.

14.3. Derivación

Sea p la probabilidad estimada de que una persona elija la marca m dentro de su conjunto de alternativas, y b_k el coeficiente del atributo k en el modelo de elección. Si esa persona pasa a asociar el atributo, la utilidad de m sube en b_k y la de las demás alternativas no cambia. Escribiendo $e = \exp(b_k)$:

$$p' = \frac{e \exp(u_m)}{D - \exp(u_m) + e \exp(u_m)}$$

donde D es la suma de exponenciales de todas las alternativas del conjunto. Dividiendo numerador y denominador por D :

$$p' = \frac{e p}{1 + (e - 1) p}$$

El resultado depende **solo** de p y b_k : es exacto y no requiere simulación. El efecto agregado sobre el share de preferencia es

$$\Delta_k = f \cdot \frac{n_k}{N} \cdot \overline{(p' - p)}$$

con f la fracción de personas que cambia de opinión, n_k el número de personas elegibles —que evaluaron la marca y aún no le asocian k —, N las personas expuestas a su industria, y el promedio tomado sobre las personas elegibles.

14.4. Alcance de la lectura

Δ_k describe **asociación**, no efecto causal. La sección del modelo multinivel muestra que la relación entre percepción y preferencia es mayoritariamente simultánea y que la componente que anticipa al año siguiente es pequeña.

Tabla 44: Escenarios de la marca mejor rankeada

Atributo	Palanca	No se lo asocian	Share actual	Puntos asociados
Es cercana	1	100	2.229	0.026
Me permite contactarla a través de person...	2	117	2.229	0.025
Es amable en el trato	3	101	2.229	0.021
Su atención y/o servicio es ágil	4	83	2.229	0.017
Sus transacciones son seguras	5	57	2.229	0.016
Usa mi mismo lenguaje	6	75	2.229	0.015
Me ofrece servicios, productos y/o benefi...	7	95	2.229	0.014
Su sitio web y/o aplicación son de uso fá...	8	63	2.229	0.013
Sus procesos son automatizados	9	74	2.229	0.013
Me hace sentir comprendido	10	106	2.229	0.012
Tiene presencia en todo Chile	11	51	2.229	0.011
Toma en cuenta y se adapta a las continge...	12	75	2.229	0.010

15. Un modelo de la preferencia en el tiempo

15.1. Especificación

Para la marca j de la industria s en el año t , sean n_{jt} las personas que la conocen y y_{jt} las que la ponen en primer lugar:

$$y_{jt} \sim \text{Binomial}(n_{jt}, \pi_{jt})$$

$$\text{logit}(\pi_{jt}) = \beta_0 + \beta_1 \tilde{P}_{jt} + \beta_2 \tilde{A}_{jt} + \beta_3 t + u_j + v_s, \quad u_j \sim N(0, \sigma_u^2), \quad v_s \sim N(0, \sigma_v^2)$$

donde $\tilde{P}_{jt}$ es la percepción estandarizada —el promedio de los atributos—, $\tilde{A}_{jt}$ el alcance estandarizado, t el año centrado en la primera edición, u_j el término propio de la marca y v_s el de la industria.

Modelar la preferencia como binomial con denominador conocido **pondera automáticamente** por el tamaño de la base: una marca con 60 evaluadores aporta menos que una con 200, sin necesidad de pesos definidos a mano. Los términos u_j y v_s producen *pooling* parcial: las marcas con poca información se acercan al promedio de su industria en vez de generar estimaciones extremas.

15.2. Separación entre y dentro

Un único coeficiente β_1 mezcla dos fuentes de variación. La descomposición de Mundlak las separa:

$$\text{logit}(\pi_{jt}) = \beta_0 + \beta_B \bar{P}_j + \beta_W (\tilde{P}_{jt} - \bar{P}_j) + \gamma_B \bar{A}_j + \gamma_W (\tilde{A}_{jt} - \bar{A}_j) + \beta_3 t + u_j + v_s$$

con $\bar{P}_j$ el promedio de la percepción de la marca en el tiempo. β_B compara **marcas distintas**; β_W sigue a **la misma marca** a lo largo del tiempo. El segundo es el relevante para decidir.

15.3. Interpretación de los coeficientes

En escala logit, $\exp(\beta)$ es el factor por el que se multiplican las probabilidades relativas de ser primera preferencia ante un aumento de una desviación estándar en el predictor.

Tabla 45: Selección de especificación por BIC

especificacion	parametros	bic	elegido
Solo diferencias entre marcas	2	1579	FALSE
Percepcion y ano	4	1359	FALSE
Con alcance e industria	6	1308	TRUE
Separando entre marcas y dentro	8	1311	FALSE

Tabla 46: Efectos estimados, ambas especificaciones

Modelo	Término	Efec- to	Error est.	z	p	IC bajo	IC alto	exp(efec- to)
Modelo elegido	percepcion_z	0.542	0.036	14.882	0.000	0.471	0.613	1.719
Modelo elegido	alcance_z	0.332	0.057	5.799	0.000	0.220	0.444	1.394
Modelo elegido	t	0.062	0.040	1.545	0.122	-0.017	0.141	1.064
Entre marcas y dentro	percep- cion_marca	0.660	0.054	12.327	0.000	0.555	0.765	1.935

Modelo	Término	Efec- to	Error est.	z	p	IC bajo	IC alto	exp(efec- to)
Entre marcas y dentro	percepcion_desvio	0.449	0.047	9.581	0.000	0.357	0.541	1.567
Entre marcas y dentro	alcance_marca	0.265	0.062	4.312	0.000	0.145	0.386	1.304
Entre marcas y dentro	alcance_desvio	0.432	0.161	2.681	0.007	0.116	0.748	1.541
Entre marcas y dentro	t	0.053	0.043	1.254	0.210	-0.030	0.137	1.055

Tabla 47: Componentes de varianza

nivel	desviacion
marca	0.369
industria	0.325

15.4. Robustez

Cuatro estimaciones del mismo efecto bajo decisiones distintas:

prueba	efecto	observaciones
Modelo principal	0.542	222
Remuestreo de marcas (mediana)	0.489	40
Percepcion del ano anterior	0.403	98
Solo marcas con base holgada	0.541	211

ic_bajo	ic_alto	replicas
0.409	0.563	40

Todas las estimaciones de robustez

El **remuestreo** sortea marcas completas con reemplazo y reestima: si el efecto dependiera de unas pocas marcas influyentes, el intervalo sería amplio. La especificación **rezagada** sustituye $\tilde{P}_{jt}$ por $\tilde{P}_{j,t-1}$: separa la asociación simultánea de la que anticipa al año siguiente. La restricción a **bases holgadas** ($n_{jt} \geq 120$) verifica que el resultado no lo produzcan las marcas peor medidas.

15.5. Limitaciones

- El modelo describe **asociación**. Ningún término admite lectura causal: percepción y preferencia se miden en la misma entrevista.
- Con tres ediciones, los términos por marca descansan en pocas observaciones cada uno. El *pooling* parcial mitiga el problema pero no lo elimina.
- La percepción entra medida con error, que no se corrige explícitamente. Su efecto probable es una atenuación: el coeficiente estimado sería una cota inferior del real.

16. Tendencias entre ediciones

16.1. Comparación de dos encuestas independientes

Cada edición entrevista a una muestra nueva. Para dos proporciones $\hat{p}_1, \hat{p}_2$ estimadas sobre n_1, n_2 personas independientes, el error estándar de su diferencia es

$$\widehat{SE}(\hat{p}_2 - \hat{p}_1) = \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n_2}}$$

Se contrasta $H_0 : p_1 = p_2$ con el estadístico $z = (\hat{p}_2 - \hat{p}_1)/\widehat{SE}$.

16.2. Control de comparaciones múltiples

Se comparan quince indicadores simultáneamente. Sin corrección, con $\alpha = 0,05$ se esperaría casi un falso positivo por edición. Se aplica el procedimiento de **Benjamini–Hochberg**, que controla la proporción esperada de falsos descubrimientos entre los declarados significativos: los valores p ordenados $p_{(1)} \leq \dots \leq p_{(m)}$ se comparan contra $\frac{i}{m}\alpha$ y se rechaza hasta el mayor i que cumple.

16.3. Regla temporal

El análisis de una edición usa esa edición y **todas las anteriores disponibles**, nunca posteriores. Un informe describe lo que se sabía en su momento.

Tabla 48: Todos los cambios evaluados, incluidos los no concluyentes

Indicador	An- tes	Aho- ra	Cam- bio	Error est.	p	p ajustado	Lectura
Mi nivel de confianza en la Inteligencia Ar...	33.7	37.4	3.7	1.685	0.028	0.244	Dentro del margen
Prefiere marcas cercanas	60.1	63.1	3.0	1.712	0.080	0.244	Dentro del margen
Prefiere marcas tecnologicas	39.9	36.9	-3.0	1.712	0.080	0.244	Dentro del margen
Importante balancear cercania y tecnologia	79.8	82.6	2.8	1.374	0.042	0.244	Dentro del margen
Espera marcas cercanas	83.7	85.9	2.2	1.262	0.081	0.244	Dentro del margen
Hay situaciones en que los seres humanos so...	85.2	83.1	-2.1	1.287	0.103	0.257	Dentro del margen
Me da miedo que los robots terminen reempla...	43.8	42.2	-1.6	1.743	0.359	0.769	Dentro del margen
Los sistemas automatizados pueden tener la ...	14.7	15.7	1.0	1.265	0.429	0.805	Dentro del margen
Paga incluso si le cuesta mas	16.6	15.7	-0.9	1.295	0.487	0.812	Dentro del margen
Los sistemas automatizados son eficientes e...	32.8	33.3	0.5	1.657	0.763	0.880	Dentro del margen
Paga si no le cuesta mas	72.6	73.1	0.5	1.566	0.750	0.880	Dentro del margen
Dispuesto a pagar	89.2	88.8	-0.4	1.102	0.717	0.880	Dentro del margen
No esta dispuesto a pagar	10.8	11.2	0.4	1.102	0.717	0.880	Dentro del margen

Indicador	An- tes	Aho- ra	Cam- bio	Error est.	p	p ajustado	Lectura
La inteligencia artificial no tiene sentido...	73.8	73.6	-0.2	1.551	0.897	0.961	Dentro del margen
Espera marcas tecnologicas	75.8	75.8	0.0	1.508	1.000	1.000	Dentro del margen

Tabla 49: Brecha entre expectativa de cercanía y de tecnología

edicion	casos	cercanas	tecnologicas	brecha	error
2023	1670	83.7	75.8	7.9	1.38
2024	1559	85.9	75.8	10.1	1.40

17. ¿Alcanza un modelo aditivo?

17.1. La pregunta

El modelo de elección del estudio es **aditivo** en los atributos: la utilidad de una marca es la suma de lo que aporta cada atributo, y ese aporte no depende de los demás. Es una decisión de modelado, no un hecho observado, y tiene una consecuencia incómoda.

La tesis central de EmpatIA —que **equilibrar** humanidad y tecnología vale más que la suma de ambas— es literalmente una interacción. Un modelo aditivo no puede detectarla aunque exista, y el Índice tampoco: un promedio ponderado es aditivo por construcción.

Este capítulo pone a competir cuatro formas funcionales sobre los mismos datos, con la misma estructura de verosimilitud. Lo único que cambia entre ellas es cómo se construye la utilidad, y eso es lo que hace la comparación interpretable.

Especificación	Utilidad	Parámetros
Aditivo (vigente)	$\sum_k \beta_k x_k$	25
Aditivo + interacciones	lo anterior, más cercana × tecnológica y el producto de los promedios de los bloques Humanidad y Tecnología	27
Red de 4 unidades	$w'_2 \tanh(W_1 x + b_1)$	108
Red de 8 unidades	lo mismo, con 8 unidades ocultas	216

17.2. Cómo se estima

Las cuatro comparten la verosimilitud condicional del Sección 6: un softmax **dentro del menú que cada persona efectivamente evaluó**.

$$P(Y_s = j) = \frac{\exp(u(x_j))}{\sum_{k \in C_s} \exp(u(x_k))}, \quad \ell = \frac{1}{S} \sum_s \log P(Y_s = y_s) - \frac{\lambda}{2} \|\theta\|^2.$$

La red no lleva sesgo en su capa de salida: una constante por alternativa se cancela dentro del softmax y no estaría identificada. La penalización ridge se aplica a **las cuatro** formas, para que la comparación sea entre formas funcionales y no entre niveles de regularización.

La verosimilitud y su gradiente analítico están escritos a mano y se optimizan con `optim()` y BFGS. No se agrega ninguna dependencia de aprendizaje profundo: con 216 parámetros no hace falta, y el código queda auditable línea a línea.

17.3. Cómo se compara

El criterio **no es el ajuste** sino el desempeño en personas que el modelo nunca vio. Con unas dos mil quinientas comparaciones y veinticinco predictores binarios, una red sobreajusta sin esfuerzo.

Se usan cinco pliegues **por persona**, no por fila: una persona aporta varias comparaciones y todas caen del mismo lado. Partirlas dejaría respuestas de la misma persona a ambos lados del corte y el resultado sería optimista.

La comparación es **pareada por pliegue**. Los pliegues difieren entre sí en dificultad, y esa variación afecta por igual a las cuatro especificaciones: compararlas por sus medias independientes cuenta esa variación dos veces y esconde diferencias reales.

Tabla 50: Desempeño fuera de muestra de cada forma funcional

Especificación	Parámetros	Log-verosimilitud	$\pm$ error	Acierto %	$\pm$ error
Red de 8 unidades	216	-1.682	0.0134	45.1	0.31
Red de 4 unidades	108	-1.684	0.0135	44.9	0.15
Aditivo + interacciones	27	-1.730	0.0125	43.9	0.45
Aditivo (especificación vigente)	25	-1.747	0.0118	43.7	0.60

Tabla 51: Ventaja pareada sobre la especificación vigente

Especificación	Ganancia en log-verosimilitud	$\pm$ error pareado	Ganancia en acierto (pp)	p	Supera su margen
Red de 8 unidades	0.0651	0.0087	1.35	0.0017	Sí
Red de 4 unidades	0.0624	0.0090	1.16	0.0023	Sí
Aditivo + interacciones	0.0168	0.0032	0.15	0.0061	Sí

17.4. Qué resulta, y cómo leerlo

Conviene separar dos preguntas que suelen confundirse.

¿Es detectable que la forma aditiva se queda corta? Sí. La prueba pareada rechaza que las formas flexibles empaten con la aditiva. Con veinticinco atributos binarios hay interacciones reales y el modelo aditivo no las recoge.

¿Vale la pena reemplazarla? No con estos datos. La ganancia es de centésimas de log-verosimilitud por comparación y menos de un punto porcentual de acierto, a cambio de pasar de 25 parámetros interpretables a 216 que no lo son. Y una parte apreciable de esa ganancia la captura la especificación intermedia —aditivo más dos interacciones— con **dos** parámetros extra.

Por eso el simulador del dashboard sigue usando la especificación vigente. Cambiar la forma funcional del simulador por una ventaja de este tamaño agregaría opacidad sin agregar exactitud, y el simulador existe justamente para que alguien pueda explicar por qué se mueve el número.

17.5. La tesis del estudio, puesta a prueba directamente

La especificación intermedia permite contestar la pregunta de frente, con un coeficiente y su error en vez de una caja negra.

Tabla 52: Términos de interacción entre humanidad y tecnología

Término	Coeficiente	Error	p	Supera su margen
cercana x tecnologica	-0.036	0.162	0.825	No
Humanidad x Tecnologia	-4.532	0.519	0.000	Sí

Cómo se lee este resultado, con cuidado. El producto de los promedios de los dos bloques resulta **negativo** y muy por sobre su margen. Tomado literalmente diría que acumular atributos de humanidad y de tecnología a la vez aporta **menos** que la suma de ambos: rendimientos decrecientes, no una bonificación por equilibrio.

Antes de llevar eso a una lámina conviene notar tres cosas:

1. **Es un efecto de saturación, no necesariamente una refutación.** Los términos lineales ya recogen gran parte del aporte. El producto captura la curvatura restante, y con predictores acotados entre 0 y 1

esa curvatura es casi siempre negativa: quien ya marca muchos atributos tiene poco margen para que uno más cambie su elección.

2. **La escala importa.** El producto de dos promedios no está centrado, así que su coeficiente no se interpreta como «el efecto del equilibrio» sino como el ajuste de curvatura condicional a los términos lineales. Un modelo centrado daría el mismo ajuste con otro número.
3. **El producto de los dos atributos del Índice —cercana × tecnológica,** el que corresponde exactamente a la fórmula publicada— **no** supera su margen. Sobre la cantidad que el estudio efectivamente publica, no hay evidencia ni a favor ni en contra de una bonificación por equilibrio.

Conclusión defendible. Los datos no respaldan que combinar humanidad y tecnología produzca un premio por sobre la suma de ambas; tampoco lo descartan para los dos atributos del Índice. La tesis del estudio se sostiene como propuesta de posicionamiento —las marcas mejor evaluadas puntúan alto en ambas— y no como un efecto multiplicativo demostrado. El informe debería enunciarla de la primera forma.

17.6. Qué aprendió la forma ganadora

Una red no entrega coeficientes legibles. Se la mira de dos maneras.

Importancia por permutación. Se baraja una columna entre marcas y se mide cuánto empeora la predicción. Se calcula igual para las formas lineales, así que las cuatro se comparan en la misma escala.

Tabla 53: Importancia por permutación en la forma ganadora

Término	Bloque	Pérdida al barajar	± error	Índice 0-100
Sus transacciones son seguras	EmpatIA	0.0577	0.0019	100
Su sitio web y/o aplicación son de uso fáci...	Tecnología	0.0442	0.0018	77
Es cercana	Humani- dad	0.0314	0.0011	54
Me permite contactarla a través de personas...	Humani- dad	0.0199	0.0012	34
Me ofrece servicios, productos y/o benefi...	EmpatIA	0.0166	0.0008	29
Tiene presencia en todo Chile	EmpatIA	0.0150	0.0008	26
Su atención y/o servicio es ágil	Tecnología	0.0142	0.0005	25
Se preocupa genuinamente de mi	Humani- dad	0.0127	0.0009	22
Es amable en el trato	Humani- dad	0.0123	0.0009	21
Sus procesos son automatizados	Tecnología	0.0119	0.0006	21
Comparte mis valores y principios	Humani- dad	0.0113	0.0009	20
Usa mi mismo lenguaje	Humani- dad	0.0105	0.0007	18
Se pone en mi lugar cuando tengo un problema	Humani- dad	0.0102	0.0007	18
Soluciona de manera efectiva mis problemas	EmpatIA	0.0081	0.0006	14
Reconoce la antigüedad de nuestra relación ...	Humani- dad	0.0065	0.0006	11

Dependencia parcial. Cuánto cambia la utilidad al pasar el atributo de ausente a presente, manteniendo todo lo demás. En la forma aditiva esto reproduce el coeficiente y su dispersión es cero por construcción. En la red, una dispersión alta señala un atributo cuyo aporte **depende del resto del perfil**: exactamente lo que el modelo aditivo no puede representar.

Tabla 54: Atributos cuyo aporte más depende del resto del perfil

Atributo	Bloque	Aporte medio	Dispersión del aporte
Se pone en mi lugar cuando tengo un problema	Humanidad	0.540	0.287
Es cercana	Humanidad	0.748	0.282
Sus transacciones son seguras	EmpatIA	0.828	0.270
Me permite contactarla a través de personas...	Humanidad	0.530	0.268
Su sitio web y/o aplicación son de uso fácil...	Tecnología	0.776	0.265
Se preocupa genuinamente de mi	Humanidad	0.620	0.262
Me ofrece servicios, productos y/o benefici...	EmpatIA	0.588	0.250
Reconoce la antigüedad de nuestra relación ...	Humanidad	0.438	0.226
Comparte mis valores y principios	Humanidad	0.550	0.219
Soluciona de manera efectiva mis problemas	EmpatIA	0.398	0.195
Sus procesos son automatizados	Tecnología	0.419	0.176
Su atención y/o servicio es ágil	Tecnología	0.478	0.166

17.7. Límites de este capítulo

- **El tamaño manda.** Con este número de comparaciones, ninguna forma flexible va a lucirse. El resultado dice qué se puede distinguir con esta muestra, no qué forma funcional es verdadera.
- **La red no se interpreta.** La importancia por permutación y la dependencia parcial son descripciones del modelo ajustado, no parámetros con error estándar propio.
- **Sigue siendo asociación.** Cambiar la forma funcional no cambia el diseño: percepción y preferencia se declaran en la misma entrevista.
- **Una sola arquitectura.** Se probó una capa oculta con dos anchos. No se exploraron profundidades mayores, otras activaciones ni otros niveles de penalización, porque con esta base ese espacio de búsqueda produciría sobreajuste de selección más que aprendizaje.

18. Reproducibilidad, controles y límites del estudio

18.1. Cómo se reproduce una edición

Desde la carpeta del año, `source("codigo/0_masterfile.R")` corre el pipeline completo y regenera tablas, figuras, informe, apéndice y datos de los dos dashboards. El único archivo que cambia de un año a otro es ese masterfile: contiene el año, la ruta a la base, el catálogo de marcas y los pesos del índice. Todo el resto del código es idéntico entre ediciones y vive en `compartido/`, que se copia a cada año en cada corrida.

Paso	Archivo	Qué produce
1	<code>1_limpieza_datos.R</code>	Tablas largas y el registro de exposición (Sección 2.2)
2	<code>2_analisis.R</code>	Puntajes, índice, rankings, importancia declarada
—	<code>inferencia.R</code>	Márgenes y las tres referencias (Sección 4.4)
3	<code>3_otros_analisis.R</code>	Modelo de elección, escenarios, posicionamiento
—	<code>deep_dive.R</code>	Recorrido, conversiones, cuadrantes, perfilamiento
—	<code>estructura.R</code>	Estabilidad del mapa con otras personas
—	<code>indice_inductivo.R</code>	Índices alternativos (Sección 8)
—	<code>tendencias.R</code>	Comparación entre ediciones
—	<code>segmentos_latentes.R</code>	Perfiles de personas y territorios de marcas
—	<code>modelo_preferencia.R</code>	Modelo multinivel entre ediciones
—	<code>modelo_neuronal.R</code>	Carrera de formas funcionales (Sección 17)
4	<code>informe.qmd</code>	Informe
5	<code>apendice_metodologico.qmd</code>	Este documento

Las semillas de todo procedimiento aleatorio están fijadas en el código. Dos corridas sobre la misma base producen las mismas cifras.

18.2. Controles automáticos

`auditoria/comprobar.R` revisa, sobre los archivos ya generados:

- que no haya personas duplicadas;
- que toda asociación con una marca venga acompañada de conocerla y de haberla evaluado;
- que las preferencias sean consistentes con el menú;
- que la fórmula del índice reproduzca las tablas publicadas;
- que las predicciones evaluadas no provengan de las mismas personas usadas para ajustar los modelos.

Además, `1_limpieza_datos.R` detiene la corrida si falla cualquiera de los tres controles de diseño de la Sección 2.2. Un supuesto de exposición roto invalida todos los denominadores, así que no se continúa con una advertencia.

18.3. Los seis límites que conviene tener presentes

1. **No es inferencia de diseño.** Muestra con cuotas, sin ponderadores de expansión documentados. Las cifras describen a las personas entrevistadas.
2. **Todo es simultáneo.** Percepción, preferencia y uso se declaran en la misma entrevista. Ninguna asociación identifica una dirección causal.

3. **Las bases son moderadas.** Alrededor de doscientas personas evalúan cada marca. Con veinticinco atributos y tres referencias, la mayoría de las diferencias individuales cae dentro del margen.
4. **El listado de marcas cambia.** Entre ediciones entran y salen marcas. Un cambio de puesto puede venir de eso y no del mercado.
5. **Los públicos se solapan.** Una misma persona está en varios. Las diferencias entre niveles de una segmentación no controlan por las otras.
6. **La ponderación corrige composición, no selección.** Los pesos de la Sección 2.3 igualan la distribución de industrias usadas entre los asignados y los usuarios. No corrigen no respuesta, cobertura ni autoselección al panel, y su propensión es estimada, no una probabilidad de diseño documentada por el proveedor.

18.4. Referencias metodológicas

- Agresti, A. (2013). *Categorical Data Analysis*, 3^a ed. Wiley. Intervalos de Wilson, logit condicional, modelos de respuesta ordenada.
- Benjamini, Y. y Hochberg, Y. (1995). Controlling the false discovery rate. *JRSS-B* 57(1), 289–300.
- Chamberlain, G. (1980). Analysis of covariance with qualitative data. *Review of Economic Studies* 47(1), 225–238. Logit de efectos fijos (Sección 6.3).
- Chan, K.-Y. y Loh, W.-Y. sobre análisis de correspondencias como residuos de un modelo multiplicativo; ver también Greenacre, M. (2017). *Correspondence Analysis in Practice*, 3^a ed. CRC Press.
- Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning*, 2^a ed. Springer. Regularización y validación cruzada.
- Horn, J. L. (1965). A rationale and test for the number of factors in factor analysis. *Psychometrika* 30, 179–185.
- Hubert, L. y Arabie, P. (1985). Comparing partitions. *Journal of Classification* 2, 193–218. Índice de Rand ajustado.
- McFadden, D. (1974). Conditional logit analysis of qualitative choice behavior. En Zarembka (ed.), *Frontiers in Econometrics*. Academic Press.
- McLachlan, G. y Peel, D. (2000). *Finite Mixture Models*. Wiley. Mezclas gaussianas y selección por BIC.
- Reise, S. P. (2012). The rediscovery of bifactor measurement models. *Multivariate Behavioral Research* 47(5), 667–696. ω_h y ECV.
- Scrucca, L. et al. (2016). mclust 5. *The R Journal* 8(1), 289–317.
- Wedderburn, R. W. M. (1974). Quasi-likelihood functions. *Biometrika* 61(3), 439–447. Familia quasibinomial de las curvas de conversión (Sección 5.2).